

Relatório PROJETO/ESTÁGIO

**Estratégias Automáticas de Remoção de Artefactos em EEG com Python/MNE:
Estudo Comparativo de Algoritmos e Combinações Híbridas**

Autor

João Pedro Ribeiro dos Santos

1200766@isep.ipp.pt

29.Abril.2026

Agradecimentos

A realização deste trabalho não teria sido possível sem o suporte, carinho e disponibilidade familiar, por esse motivo deixo aqui o meu profundo agradecimento a todos eles. Queria também aproveitar para agradecer de forma geral a todos os docentes com quem me cruzei ao longo da Licenciatura e à Dr. Gisela Maia pela sua disponibilidade e conhecimento partilhado.

RESUMO

Este trabalho teve como objetivo analisar e comparar estratégias automáticas de pré-processamento de sinais de eletroencefalogramas (EEG), implementadas em Python com recurso à biblioteca MNE, a fim de identificar uma abordagem eficaz, reproduzível e com custo computacional compatível com a utilização prática. Para esse efeito, foram estudados os métodos AutoReject e ICA+ICLabel, bem como duas pipelines híbridas construídas por meio da combinação sequencial entre ambos.

A avaliação foi realizada em seis sinais EEG com características distintas, recorrendo a métricas quantitativas orientadas para artefactos oculares, musculares e ruído de linha, inspeção visual no domínio temporal e espectral, análise da variação do Brain Symmetry Index e medição do tempo total de execução. Os resultados mostraram que o ICA+ICLabel foi a abordagem com melhor comportamento global, evidenciando maior consistência entre sinais, melhor capacidade de limpeza e menor tempo de execução. O AutoReject revelou maior utilidade como ferramenta complementar de refinamento local do que como núcleo principal do pipeline. Conclui-se, assim, que o ICA+ICLabel constitui a base mais sólida para um pipeline automático de pré-processamento de EEG no contexto analisado.

Palavras-Chave

Eletroencefalografia, pré-processamento de sinais, remoção de artefactos, métodos automáticos, métodos híbridos, ICA, ICLabel, AutoReject, Python, MNE.

Abstract

This work aimed to analyze and compare automatic EEG preprocessing strategies implemented in Python using the MNE library, to identify an approach that is effective, reproducible, and computationally feasible for practical use. For this purpose, the methods AutoReject and ICA+ICLabel were studied, as well as two hybrid pipelines built from their sequential combination.

The evaluation was carried out on six EEG recordings with different characteristics, using quantitative metrics related to ocular artifacts, muscular artifacts, and line noise, together with visual inspection in the time and spectral domains, Brain Symmetry Index variation, and total execution time. The results showed that ICA+ICLabel achieved the best overall performance, with greater consistency across signals, better cleaning capability, and lower execution time. AutoReject proved to be more useful as a complementary local refinement tool than as the core of the preprocessing pipeline. It is therefore concluded that ICA+ICLabel provides the most solid basis for an automatic EEG preprocessing pipeline in the analyzed context.

Keywords

Electroencephalogram, Signals preprocessing, Hybrid Methods, Automatic Methods, Independent Component Analysis, ICLabel, AutoReject

Índice

1	Introdução	10
1.1	Caracterização da Empresa	11
1.2	Motivação.....	11
1.3	Objetivos	12
1.4	Métodos	13
2	Estado da arte	15
2.1	Enquadramento Geral da Remoção de artefactos em EEG.....	16
2.2	Métodos Convencionais.....	17
2.2.1	Métodos baseados em canais de referência	17
2.2.2	Métodos de filtragem e análise tempo-frequência	18
2.2.3	Métodos de decomposição adaptativa	20
2.2.4	Métodos de Separação Cega de Fontes	22
2.3	Métodos Automáticos de classificação e remoção de artefactos	24
2.3.1	Métodos automáticos de identificação de componentes	25
2.3.2	Métodos automáticos de rejeição e reparação de segmentos	26
2.4	Métodos híbridos	27
2.4.1	Fundamentação das abordagens híbridas	28
2.4.2	Principais combinações híbridas na literatura	28
2.5	Síntese crítica	30
3	Desenvolvimento	31
3.1	Dados e Sinais Analisados	32
3.1.1	MNE Sample.....	32
3.1.2	Sub-001	32
3.1.3	PN00-1 a PN00-4.....	33
3.1.4	Pré-condições e oportunidades dos datasets.....	33
3.2	Pipeline Base Padronizado.....	34
3.2.1	Montagem e verificação das posições dos canais.....	35
3.2.2	Referenciação aplicada (CAR)	35
3.2.3	Filtragem aplicada.....	35
3.3	ICA+ICLabel	36

3.4	AutoReject	37
3.5	Pipelines Híbridas	38
3.6	Protocolo de Avaliação e Métricas.....	40
3.6.1	Métricas Quantitativas	40
3.6.2	Análise Visual no domínio temporal e espectral	41
3.6.3	Preservação de informação clinicamente interpretável	42
3.6.4	Custo Computacional.....	43
3.6.5	CrITÉrios de decisão final.....	43
4	Resultados.....	44
4.1	Resultados por Sinal.....	45
4.1.1	MNE Sample	45
4.1.2	Sub00-1	47
4.1.3	PN00-1	50
4.1.4	PN00-2	52
4.1.5	PN00-3	55
4.1.6	PN00-4	58
4.2	Comparação Global entre Algoritmos.....	61
4.2.1	Síntese quantitativa das métricas de artefacto	61
4.2.2	Ruído de linha: leitura global das métricas e do PSD.....	62
4.2.3	Comparação visual global entre algoritmos.....	63
4.2.4	Síntese operacional de execução.....	64
5	Discussão	66
5.1	Leitura crítica das métricas	67
5.2	Justificação do destaque do ICA+ICLabel	68
5.3	Aplicabilidade prática das estratégias híbridas.....	69
6	Conclusão	71
6.1	Conclusão	72
6.2	Trabalhos Futuros.....	73
6.3	Comentários.....	74
	Bibliografia	75

Lista de Símbolos e Abreviaturas

BSS	<i>Separação cega de fontes</i>
CCA	<i>Análise canónica correlacional</i>
CEEMD	<i>Decomposição completa em modos empíricos em conjunto</i>
DWT	<i>Transforma de wavelet discreta</i>
ECG	<i>Eletrocardiograma</i>
ECTS	<i>Sistema de créditos transferíveis europeus</i>
EEMD	<i>Decomposição em modos empíricos em conjunto</i>
EEG	<i>Eletroencefalograma</i>
EMD	<i>Decomposição em modos empíricos</i>
EMG	<i>Eletromiografia</i>
EOG	<i>Eletrooculograma</i>
EU	<i>União Europeia</i>
HOS	<i>Estatísticas de ordem superior</i>
IMF	<i>Função modal intrínseca</i>
ICA	<i>Análise de componentes independentes</i>
ICs	<i>Componentes independentes</i>
LMS	<i>Mínimos quadrados médios</i>
MCA	<i>Análise de componentes morfológicos</i>
MC	<i>Multicanal</i>
NMD	<i>Decomposição em modos não lineares</i>
RLS	<i>Mínimos quadrados recursivos</i>
PCA	<i>Análise de componentes principais</i>
PCs	<i>Componentes principais</i>
PSD	<i>Densidade espectral de potência</i>
SC	<i>Mono canal</i>
SCDM	<i>Métodos de decomposição de monos canais</i>
SCICA	<i>Análise de componentes independentes monos canais</i>
SNR	<i>Razão sinal-ruído</i>
SOBI	<i>Identificação cega de segunda ordem</i>

SOS	<i>Estatísticas de segunda ordem</i>
SWT	<i>Transformada de Wavelet sincronizada</i>
WT	<i>Transformada de Wavelet</i>

1 Introdução

Caracterização da Empresa

Motivação

Objetivos

Métodos

1.1 Caracterização da Empresa

A Medibrain – Clínica Médica, Neurofisiologia e Bem-estar distingue-se enquanto instituição de carácter multidisciplinar, especializada na prevenção, diagnóstico e tratamento de distúrbios neurológicos, integrando serviços de elevada qualidade. A clínica, fundada sobre os alicerces da neurofisiologia, expandiu progressivamente o seu leque de atuações para incluir especialidades como neurologia, psiquiatria, neuropsicologia, psicologia clínica, medicina do sono, nutrição, osteopatia, entre outras.

O corpo clínico da clínica é altamente qualificado, com ligações ao ensino superior e à investigação em neurociências. Atualmente conta com 16 profissionais. A Medibrain distingue-se também pela aposta contínua na formação profissional e no rigor científico, refletido na prática clínica e no empenho docente dos seus profissionais.

1.2 Motivação

Atualmente, observa-se um aumento significativo no número de diagnósticos de doenças neurológicas e neurodegenerativas, tais como epilepsia, perturbações do sono, demência, doença de Parkinson, doença de Alzheimer, bem como certas condições psiquiátricas (Feigin et al., 2021). Portugal não é exceção a esta tendência (Tuna, 2024).

Um aspeto comum a todas estas patologias é o impacto direto na atividade elétrica cerebral dos pacientes. Compreender esta atividade deixou de ser uma mera curiosidade científica e passou a constituir uma necessidade clínica fundamental. Neste contexto, os eletroencefalogramas (EEG) tornaram-se exames imprescindíveis, cada vez mais requisitados tanto para investigação como para apoio ao diagnóstico.

Não obstante, o EEG caracteriza-se por apresentar sinais altamente sensíveis, facilmente influenciados por artefactos e fatores externos (Delorme, 2023) , o que dificulta a correta interpretação clínica. Por este motivo, torna-se essencial garantir que apenas a atividade elétrica cerebral relevante seja analisada, sendo necessário aplicar técnicas de pré-processamento. Este processo, fundamental em qualquer análise de EEG, pode ser definido como o conjunto de

procedimentos destinados a separar a atividade cerebral verdadeira de potenciais ruídos ou interferências (BrainVision, 2023).

Apesar da vasta variedade de técnicas atualmente disponíveis para remoção de artefactos em EEG não existe consenso científico sobre qual estratégia oferece o melhor desempenho universal (Urigüen & Garcia-Zapirain, 2015). A escolha do método depende, em grande medida, da natureza dos artefactos, da qualidade do registo e do objetivo clínico ou experimental em causa. Esta ausência de uniformidade metodológica não só reflete a complexidade inerente do EEG, mas também reforça a necessidade de investigar, comparar e otimizar pipelines automáticas que conciliem eficácia de limpeza com preservação da atividade cerebral.

1.3 Objetivos

O objetivo geral deste trabalho consiste em desenvolver e validar um método automático de pré-processamento de sinais EEG em Python, recorrendo à biblioteca MNE, capaz de reduzir artefactos de forma robusta e reproduzível, com custo computacional compatível com utilização prática e potencial integração futura numa plataforma de processamento/visualização.

Para cumprir o objetivo geral, foram definidos os seguintes objetivos específicos:

- Definir um pipeline base padrão, para garantir consistência entre sinais e permitir comparações justas entre métodos.
- Implementar e configurar dois métodos de pré-processamento com enfoque em automatização, ICA+ICLabel e AutoReject, assegurando parâmetros e condições de aplicação coerentes com as recomendações das ferramentas.
- Avaliar o desempenho de cada método em diferentes sinais EEG, incluindo sinais com elevada contaminação, recorrendo a métricas quantitativas indicativas de artefactos, análise visual no domínio temporal e no domínio das frequências PSD e medição do tempo de execução como proxy de custo computacional.
- Explorar pipelines híbridas fundamentadas na bibliografia, analisando vantagens, limitações e trade-offs.

- Selecionar a abordagem final com base num critério de decisão que considere simultaneamente qualidade de limpeza e eficiência computacional, justificando a escolha com evidência experimental.

1.4 Métodos

A estratégia seguida neste projeto foi orientada por requisitos práticos típicos de um pipeline automático de EEG. Em primeiro lugar, o método deveria ser automático, reduzindo ao mínimo decisões manuais e garantindo que os mesmos passos são executados de forma consistente em diferentes sinais. Em segundo lugar, deveria ser robusto face à variabilidade natural dos dados como por exemplo a diferentes níveis de ruído, a diferenças entre datasets e à presença de períodos com elevada contaminação. Em terceiro lugar, o pipeline deveria ser reproduzível, isto é, capaz de produzir resultados consistentes quando aplicado repetidamente nas mesmas condições. Por fim, o método deveria apresentar custo computacional controlado, uma vez que tempos de execução demasiado elevados limitam a aplicabilidade prática e dificultam a futura integração do pré-processamento numa solução de uso contínuo.

A seleção dos métodos-base foi guiada por dois critérios, sendo o primeiro serem técnicas com suporte e integração sólida no ecossistema MNE e o segundo serem compatíveis com um objetivo de automatização do pré-processamento.

O AutoReject foi escolhido por ser um método orientado à deteção e correção automática de artefactos em epochs, através de estratégias como interpolação de canais e, quando necessário, rejeição de segmentos irrecuperáveis. A sua principal vantagem é a capacidade de atuar de forma relativamente sistemática sem intervenção manual, sendo particularmente útil para lidar com outliers temporais e episódios transitórios de degradação do sinal.

O ICA+ICLabel, por sua vez, foi escolhido por permitir uma abordagem de correção baseada em separação de fontes e classificação automática de componentes. Na prática, esta combinação possibilita identificar e remover componentes associadas a categorias típicas de artefactos, mantendo o máximo possível do conteúdo cerebral. Além disso, quando corretamente

configurado, o ICLabel permite reduzir a subjetividade do processo de seleção de componentes, aproximando o método de um funcionamento verdadeiramente automático.

Assim, AutoReject e ICA+ICLabel foram selecionados por representarem duas filosofias complementares, uma estratégia centrada na qualidade dos epochs e outra centrada na separação e remoção de fontes de ruído. A comparação entre ambas, bem como a exploração de combinações híbridas, permitiu avaliar qual abordagem oferece o melhor compromisso entre qualidade de limpeza e tempo de execução no contexto dos sinais analisados.

2 Estado da arte

Enquadramento Geral

Métodos Convencionais

Métodos Automáticos

Métodos Híbridos

Síntese Crítica

O pré-processamento de sinais de EEG tem sido alvo de investigação intensiva, dado o impacto decisivo que a qualidade do sinal exerce sobre a fiabilidade das análises subsequentes. Ao longo das últimas décadas, diversas abordagens foram propostas para mitigar artefactos e preservar a atividade neurofisiológica, variando desde métodos convencionais de filtragem e decomposição até técnicas automáticas e híbridas baseadas em aprendizagem automática. Este estado da arte procura sistematizar essas estratégias, discutindo a sua evolução, princípios de funcionamento e relevância no contexto atual da análise de EEG.

2.1 Enquadramento Geral da Remoção de artefactos em EEG

O pré-processamento de sinais de eletroencefalografia constitui uma etapa fundamental em qualquer pipeline de análise, uma vez que a qualidade do sinal condiciona diretamente a fiabilidade das etapas subsequentes, desde a inspeção visual até à extração de características, deteção de eventos e classificação automática. A presença de artefactos pode comprometer a interpretação neurofisiológica do registo, mascarar atividade cerebral relevante ou introduzir distorções no sinal que afetam negativamente a análise (Jiang et al., 2019; Kline et al., 2022; Urigüen & Garcia-Zapirain, 2015).

A remoção de artefactos em EEG é, contudo, um problema particularmente exigente. O sinal eletroencefalográfico não é estacionário, varia no tempo e resulta da sobreposição de múltiplas fontes cerebrais e não cerebrais. Além disso, muitos artefactos partilham características temporais ou espectrais com a atividade neuronal, o que dificulta a sua separação sem risco de distorcer ou atenuar informação útil. Esta dificuldade torna especialmente relevante a escolha de métodos capazes de equilibrar a limpeza do sinal com a preservação do seu conteúdo fisiologicamente interpretável (Urigüen & Garcia-Zapirain, 2015).

Entre os principais tipos de artefactos presentes em EEG destacam-se os artefactos oculares, os artefactos musculares, os artefactos cardíacos, o ruído de linha elétrica e ainda interferências associadas a movimento como mau contacto dos elétrodos ou ruído de canal (Jiang et al., 2019). A diversidade destes artefactos explica a inexistência de uma solução única universalmente

ótima, levando ao desenvolvimento de múltiplas abordagens com princípios de funcionamento distintos (Kline et al., 2022).

Neste contexto, a revisão apresentada neste capítulo será organizada em três grandes famílias de métodos. Os métodos convencionais, os métodos automáticos e os métodos híbridos. Esta estrutura permite enquadrar a evolução das estratégias de remoção de artefactos em EEG, desde abordagens mais clássicas de filtragem, decomposição e separação de fontes, até soluções mais recentes orientadas para automação e combinação de técnicas. Deste modo, o estado da arte fica alinhado com os objetivos do presente projeto e com a necessidade de identificar abordagens metodológicas adequadas para a construção de um pipeline de pré-processamento robusto e reproduzível.

2.2 Métodos Convencionais

Os métodos convencionais de remoção de artefactos são as abordagens mais clássicas no pré-processamento de sinais de EEG. Apesar de muitas destas técnicas terem sido parcialmente substituídas por abordagens automáticas e híbridas mais recentes, continuam a ser relevantes, quer como ponto de referência metodológico, quer em contextos específicos em que a sua simplicidade, interpretabilidade ou baixo custo computacional constituem vantagens práticas.

2.2.1 Métodos baseados em canais de referência

Entre os métodos convencionais, um primeiro grupo importante é constituído pelas abordagens que dependem da existência de canais de referência capazes de registar, de forma predominante, o artefacto a remover. Nesta categoria incluem-se, sobretudo, a regressão linear e os filtros adaptativos, ambos particularmente utilizados para corrigir artefactos oculares e cardíacos. A principal vantagem destas técnicas reside na sua simplicidade conceptual e na possibilidade de modelar diretamente a contribuição do artefacto no EEG (Croft & Barry, 2000). No entanto, a sua utilidade depende fortemente da disponibilidade e qualidade desses canais adicionais (Fatourechi et al., 2007).

A regressão linear foi uma das primeiras técnicas amplamente utilizadas para remover artefactos em EEG, sobretudo interferências oculares e cardíacas. O método baseia-se em canais de referência, como EOG ou ECG, a partir dos quais se estima a contribuição do artefacto em cada canal de EEG para posterior subtração. A sua principal vantagem é a simplicidade, aliada a um baixo custo computacional (Croft & Barry, 2000). No entanto, a técnica depende fortemente da disponibilidade e qualidade dos canais de referência e assume uma relação linear entre o artefacto e a sua projeção no EEG, o que limita o seu desempenho em sinais não lineares e não estacionários (Molla et al., 2012). Atualmente, a regressão linear é usada sobretudo como baseline ou em contextos específicos onde existem referências adequadas (Romero et al., 2009).

Os filtros adaptativos seguem a mesma lógica geral de utilização de canais de referência, mas introduzem uma atualização iterativa dos coeficientes do filtro, permitindo modelar o artefacto de forma mais dinâmica. O sinal estimado é depois subtraído ao EEG, originando um sinal corrigido.




Figura 1- Ilustração do funcionamento do Filtro Adaptativo, (Garcés Correa et al., 2007)

Entre os algoritmos mais utilizados destacam-se o LMS, de menor complexidade, e o RLS, geralmente mais preciso. Quando comparados com a regressão linear, os filtros adaptativos são mais flexíveis, podendo adaptar-se a variações temporais do artefacto e, em alguns casos, operar em tempo real. Ainda assim, a sua principal limitação continua a ser a dependência de canais de referência adequados, o que restringe a sua aplicação sobretudo à remoção de artefactos oculares e cardíacos (Sweeney et al., 2012).

2.2.2 Métodos de filtragem e análise tempo-frequência

Outro grupo relevante de métodos convencionais inclui as abordagens baseadas em filtragem estatística e em análise tempo-frequência, particularmente úteis quando os artefactos apresentam uma assinatura espectral relativamente bem definida. Nestes casos, a remoção pode ser orientada para bandas específicas do sinal, procurando atenuar o ruído sem recorrer necessariamente a canais de referência. No entanto, a principal limitação destas técnicas surge quando existe sobreposição espectral entre o artefacto e a atividade neuronal de interesse, situação frequente em sinais de EEG (Al-Fahoum & Al-Fraihat, 2014).

Entre as abordagens clássicas deste grupo encontram-se os filtros de Wiener, que procuram estimar o sinal limpo minimizando o erro quadrático médio entre o sinal observado e a sua reconstrução. A sua aplicação depende da caracterização prévia das propriedades espectrais do sinal e do ruído, normalmente através da densidade espectral de potência. Quando bem parametrizados, estes filtros podem alcançar boa fidelidade de reconstrução além de apresentarem a vantagem de não dependerem de canais de referência. Ainda assim, a necessidade de estimação prévia das características estatísticas do sistema limita a sua utilização a contextos offline, reduzindo a sua adequação a pipelines automáticas ou a aplicações em tempo real (Sweeney et al., 2012).

Numa linha mais probabilística, surgem os filtros Bayesianos, que estimam o estado do sistema a partir de observações ruidosas com base num modelo dinâmico. Em vez de se centrarem apenas no espectro do sinal, recorrem a processos iterativos de predição e correção, frequentemente implementados por aproximações como os filtros de Kalman ou os filtros de partículas (Crisan, 2001; Welch & Bishop, 2006). Estas abordagens têm interesse por dispensarem canais de referência e, em alguns casos, permitirem operação em tempo real. No entanto, a sua maior complexidade algorítmica, aliada à necessidade de calibração cuidada, faz com que a sua utilização no pré-processamento corrente de EEG seja mais limitada (Sweeney et al., 2012).

A Transformada de Wavelet (WT) e a sua variante mais utilizada, a Transformada Wavelet Discreta (DWT), representam uma das abordagens mais relevantes dentro da análise tempo-frequência (Talebi, 2020). A sua principal vantagem reside na capacidade de representar o sinal simultaneamente no domínio temporal e espectral, permitindo decompor o EEG em várias escalas ou sub-bandas e atuar seletivamente sobre componentes associadas a artefactos. Esta

característica torna-as particularmente úteis em sinais não estacionários, como o EEG, e em situações em que os artefactos apresentam uma distribuição espectral relativamente localizada (Safieddine et al., 2012).

De forma geral, o procedimento envolve três etapas. A decomposição do sinal, a limiarização ou atenuação dos coeficientes associados ao ruído e a reconstrução do sinal limpo. Quando bem parametrizadas, a WT e a DWT permitem atenuar artefactos oculares ou musculares preservando uma parte substancial da atividade neural (Safieddine et al., 2012). No entanto, a eficácia destas técnicas depende fortemente da escolha da wavelet-mãe, do nível de decomposição e da estratégia de limiarização (Krishnaveni et al., 2006). Mais importante ainda, a sua capacidade de separação diminui quando o artefacto e o EEG partilham a mesma banda espectral, podendo a remoção do ruído ser acompanhada pela supressão de conteúdo cerebral relevante (Urigüen & Garcia-Zapirain, 2015).

Por essa razão, embora a WT e a DWT permaneçam ferramentas versáteis e amplamente utilizadas, a sua aplicação isolada nem sempre é suficiente para garantir uma separação robusta entre artefacto e atividade cerebral. Este aspeto explica, em parte, o facto de estas técnicas surgirem frequentemente integradas em abordagens híbridas, onde são combinadas com métodos de separação de fontes ou com estratégias adaptativas para aumentar a seletividade da remoção (Krishnaveni et al., 2006).

2.2.3 Métodos de decomposição adaptativa

Os métodos de decomposição adaptativa ocupam um lugar importante no processamento de EEG por terem sido desenvolvidos para sinais não lineares e não estacionários, características que descrevem adequadamente o sinal eletroencefalográfico (Carvalho et al., 2020). Ao contrário de abordagens baseadas em funções-base fixas, estas técnicas ajustam-se ao próprio conteúdo do sinal e procuram decompô-lo em componentes elementares com significado oscilatório (Wainwright Royal Society, 1998).

A Decomposição em Modos Empíricos (EMD) foi uma das primeiras técnicas desta família a ganhar relevância no EEG. O seu princípio baseia-se na decomposição iterativa do sinal em funções modais intrínsecas (IMFs), obtidas a partir dos máximos e mínimos locais do próprio sinal. Estas componentes podem depois ser analisadas para identificar quais estão mais associadas a artefactos e quais preservam atividade cerebral relevante. A principal vantagem do EMD é o seu carácter totalmente orientado por dados, sem necessidade de funções-base pré-definidas, o que lhe confere grande flexibilidade em sinais dinâmicos. No entanto, apresenta limitações importantes, sobretudo a mistura de modos, a sensibilidade ao ruído e o custo computacional elevado, que dificultam a sua aplicação em tempo real (Molla et al., 2012).

Com o objetivo de ultrapassar estas fragilidades, surgiram extensões como a EEMD e a CEEMD. A EEMD introduz ruído branco controlado no sinal e repete a decomposição várias vezes, calculando depois a média das IMFs correspondentes. Esta estratégia melhora a separação modal e reduz a mistura de modos, tornando a decomposição mais robusta em situações com forte interferência ou sobreposição espectral, como acontece frequentemente com artefactos oculares e musculares. A CEEMD, por sua vez, aperfeiçoa esta lógica ao utilizar pares de ruído com sinais opostos, procurando reduzir o ruído residual que ainda pode persistir após a média. Em ambos os casos, o ganho em robustez e qualidade da decomposição é acompanhado por um aumento adicional da complexidade computacional, o que restringe a sua utilização sobretudo a cenários offline (Wu & Huang, 2009).

Numa linha diferente, o VMD (Variational Mode Decomposition) representa uma evolução importante por introduzir uma formulação variacional e matematicamente mais bem definida do problema de decomposição. Em vez de recorrer a um processo recursivo heurístico, o VMD procura extrair modos de largura de banda limitada de forma mais controlada, produzindo componentes mais estáveis e com menor mistura modal. Esta característica torna-o particularmente interessante para sinais biomédicos complexos. Ainda assim, a sua aplicação prática continua dependente de uma parametrização cuidada, nomeadamente na escolha do número de modos e de outros parâmetros de convergência, o que aumenta a dificuldade de utilização e o custo computacional (Dragomiretskiy & Zosso, 2014).

De forma mais breve, importa referir também a NMD (Nonlinear Mode Decomposition), proposta como uma alternativa teoricamente mais rigorosa às abordagens empíricas anteriores.

A NMD procura melhorar a robustez ao ruído e a precisão na extração de modos oscilatórios, mas a sua aplicação à remoção de artefactos em EEG permanece ainda pouco documentada, pelo que o seu papel no estado da arte continua, para já, mais promissor do que consolidado (Iatsenko et al., 2015).

Em síntese, os métodos de decomposição adaptativa revelam-se particularmente adequados para sinais de EEG não lineares, não estacionários e, em muitos casos, de canal único ou com estrutura complexa. A sua principal força reside na capacidade de adaptar a decomposição ao próprio sinal, mas essa vantagem é frequentemente acompanhada por limitações relevantes em termos de robustez, dependência de parâmetros e custo computacional, o que explica a sua predominância em aplicações offline e a sua integração frequente em abordagens híbridas.

2.2.4 Métodos de Separação Cega de Fontes

Os métodos de Separação Cega de Fontes (BSS) ocupam um lugar central no pré-processamento de EEG, sobretudo em configurações multicanais, por permitirem separar componentes cerebrais e artefactuais sem recorrer a canais de referência. O princípio geral destas abordagens consiste em assumir que os sinais registados pelos elétrodos correspondem a misturas de várias fontes subjacentes e que essas fontes podem ser estimadas explorando propriedades estatísticas e temporais presentes nos próprios dados. No contexto da remoção de artefactos, esta família de métodos tornou-se particularmente relevante pela sua capacidade de isolar interferências oculares e musculares, frequentemente difíceis de remover por simples filtragem (Choi et al., 2005).

Entre os métodos de BSS, a ICA, Análise de Componentes Independentes, é a abordagem mais difundida. O seu objetivo é decompor o EEG em componentes independentes (ICs), que depois podem ser analisadas e classificadas como cerebrais ou artefactuais antes da reconstrução do sinal. A sua grande vantagem reside na elevada eficácia na separação de artefactos oculares e musculares em sinais multicanais, o que explica a sua presença recorrente em pipelines modernas de pré-processamento. No entanto, a ICA depende de pressupostos fortes, como a independência estatística das fontes, a não gaussianidade dos sinais e a linearidade da mistura.

Além disso, existe uma limitação estrutural importante. O número de componentes recuperáveis não pode exceder o número de canais disponíveis, o que reduz a eficácia da técnica em sinais com poucos canais e a torna pouco adequada à aplicação direta em sinais de canal único (Sweeney et al., 2012).

A CCA, Análise de Correlação Canónica, segue uma lógica distinta. Enquanto a ICA explora sobretudo a independência estatística e estatísticas de ordem superior, a CCA baseia-se na não correlação e na auto correlação temporal das fontes estimadas. Em termos práticos, esta diferença torna a CCA particularmente interessante para a remoção de artefactos musculares, que frequentemente apresentam características temporais distintas da atividade cerebral. Entre as suas vantagens destacam-se a menor complexidade computacional, a maior reprodutibilidade e o bom desempenho mesmo com menor quantidade de dados. Ainda assim, a sua eficácia diminui quando os artefactos e os sinais neurais apresentam padrões temporais semelhantes, razão pela qual a CCA surge frequentemente combinada com outras técnicas, como wavelets ou EEMD (Safieddine et al., 2012).

A PCA, Análise de Componentes Principais, embora historicamente importante, tem hoje um papel mais limitado na remoção direta de artefactos (Urigüen & Garcia-Zapirain, 2015). A técnica decompõe o sinal em componentes ortogonais ordenadas por variância, o que pode ser útil quando os artefactos apresentam amplitude muito elevada. No entanto, a PCA assume ortogonalidade entre artefacto e atividade neural, uma condição raramente satisfeita em EEG real. Por essa razão, é mais frequentemente utilizada como etapa auxiliar de redução de dimensionalidade ou de pré-processamento antes de outros métodos de BSS, do que como solução principal de limpeza (Choi et al., 2005).

Quando a aquisição é feita com apenas um canal, a limitação estrutural da BSS clássica torna-se particularmente evidente. Para estes casos foi proposta a SCICA, Análise de Componentes Independentes de Canal Único, que cria um espaço multidimensional artificial a partir de versões temporalmente desfasadas do sinal original e aplica depois algoritmos ICA convencionais sobre essa representação. Esta estratégia permite estender a lógica da ICA a sinais de canal único, sendo por isso relevante em dispositivos portáteis ou cenários com reduzido número de sensores. Ainda assim, o seu desempenho depende fortemente da qualidade dessa

reconstrução artificial e da parametrização escolhida, o que limita a sua robustez e generalização (Davies & James, 2007).

Mais recentemente, surgiram abordagens como a IVA, Análise de Vetores Independentes, que pode ser vista como uma extensão da ICA para múltiplos conjuntos de dados correlacionados. No contexto de EEG, esta técnica tem mostrado interesse sobretudo na segregação de artefactos musculares, beneficiando da exploração simultânea de informação estatística e temporal (Kim et al., 2006). Apesar do seu potencial, a sua maior complexidade de implementação faz com que o seu uso permaneça mais associado a contextos de investigação do que a pipelines correntes. De forma mais breve, pode ainda referir-se a MCA, Análise de Componentes Morfológicos, que procura separar componentes com base em diferenças estruturais e em dicionários específicos, mas cuja dependência de conhecimento prévio e menor capacidade de generalização a tornam menos adequada a pipelines automáticas (Yong et al., 2009).

Em síntese, os métodos de separação cega de fontes representam uma das famílias mais importantes no pré-processamento de EEG multicanal. A ICA destaca-se pela sua eficácia geral e versatilidade, enquanto a CCA oferece uma alternativa mais leve e particularmente útil na remoção de artefactos musculares. A principal limitação comum destas abordagens prende-se com a dependência do número de canais disponíveis e com a necessidade de identificar corretamente as componentes artefactuais, uma vez que uma separação estatisticamente eficaz não garante, por si só, uma remoção correta do ruído.

2.3 Métodos Automáticos de classificação e remoção de artefactos

O desenvolvimento de métodos automáticos representa uma das evoluções mais relevantes no pré-processamento de EEG, sobretudo pela necessidade de reduzir a intervenção manual, aumentar a reprodutibilidade e tornar os pipelines mais adequados a conjuntos de dados extensos e a aplicações escaláveis.

2.3.1 Métodos automáticos de identificação de componentes

Os métodos automáticos de identificação de componentes independentes surgiram como uma resposta à forte dependência da inspeção manual nas pipelines baseadas em ICA. A possibilidade de classificar automaticamente as ICs artefactuais permitiu aumentar a reprodutibilidade, reduzir a intervenção do utilizador e aproximar o pré-processamento de EEG de uma lógica mais automática e escalável. Entre os métodos mais utilizados nesta etapa destacam-se o ADJUST, o FASTER e o SASICA. O ADJUST utiliza características espaciais e temporais para identificar automaticamente componentes relacionadas sobretudo com artefactos oculares (Mognon et al., 2011). O FASTER aplica limiares estatísticos em múltiplos domínios, como o temporal, o espacial e o espectral, permitindo a deteção quase totalmente automática de componentes e canais contaminados (Nolan et al., 2010). Já o SASICA integra diferentes abordagens automáticas, incluindo métricas herdadas de métodos anteriores, mas mantém uma componente de validação visual por parte do utilizador, funcionando como uma solução intermédia entre automação e supervisão manual (Chaumon et al., 2015).

Apesar da utilidade destes métodos, o seu desempenho depende fortemente da qualidade da decomposição ICA e da capacidade de generalização das regras ou limiares utilizados. Além disso, alguns deles apresentam limitações claras na cobertura dos diferentes tipos de artefacto, sendo mais eficazes em cenários específicos do que como classificadores abrangentes (Echtioui et al., 2020). Neste contexto, o ICLabel destacou-se como uma das abordagens mais modernas e amplamente adotadas para a classificação automática de componentes independentes. Desenvolvido por investigadores da University of California, San Diego, o método foi treinado com mais de 200.000 componentes independentes extraídas de mais de 6.000 gravações EEG, incluindo milhares de exemplos rotulados manualmente por especialistas e voluntários. Esta base de treino alargada permitiu construir um classificador com maior robustez e melhor capacidade de generalização (Pion-Tonachini et al., 2019).

O ICLabel distingue-se por conseguir classificar cada componente em sete categorias principais: “Brain, Muscle, Eye, Heart, Line Noise, Channel Noise e Other”. Para isso, combina um conjunto rico de características espaciais, temporais e espectrais, incluindo topografias do escalpe,

medidas PSD, funções de auto correlação temporal, modelos de dipolos equivalentes e outras características herdadas de métodos como o ADJUST, o FASTER e o SASICA. Acrescenta ainda medidas estatísticas complementares, como variância, curtose temporal e Hurst exponent, e integra as classificações através do algoritmo Crowd Labeling Latent Dirichlet Allocation (CL-LDA). Nos últimos anos, o ICLabel assumiu-se como uma ferramenta de referência para classificação automática de componentes em pipelines baseadas em ICA, precisamente por combinar abrangência, automatização e facilidade de integração prática em Python (Delorme et al., 2024; Li et al., 2022).

Em síntese, os métodos automáticos de identificação de componentes representam um avanço importante face à classificação manual, sobretudo pela melhoria em objetividade e escalabilidade. Entre eles, o ICLabel destaca-se claramente pela sua capacidade de lidar com múltiplos tipos de artefacto e por se ter afirmado como solução padrão em muitas pipelines modernas de pré-processamento de EEG. Ainda assim, tal como nos restantes classificadores desta família, o seu desempenho continua dependente da qualidade da ICA a montante, o que significa que a automação da classificação não substitui a necessidade de uma decomposição de fontes robusta.

2.3.2 Métodos automáticos de rejeição e reparação de segmentos

Entre os métodos automáticos de pré-processamento, o AutoReject destaca-se por introduzir uma abordagem especificamente orientada para a deteção, rejeição e reparação automática de segmentos contaminados em sinais de EEG e MEG. Proposto por (Jas et al., 2017), o método surgiu como resposta à forte dependência de limiares de rejeição definidos manualmente, os quais, além de consumirem tempo, variam frequentemente entre utilizadores e conjuntos de dados. A sua principal inovação consiste em substituir essa escolha empírica por uma estratégia data-driven, baseada na estimação automática de limiares ótimos de amplitude pico-a-pico através de validação cruzada.

O método foi inicialmente formulado numa versão global, em que se aprende um único limiar comum a todos os canais, e posteriormente estendido para uma versão local, mais sofisticada, em que são estimados limiares específicos para cada sensor. Esta segunda abordagem permite identificar, em cada época, quais os canais contaminados e decidir entre duas ações. A interpolação de canais maus, até um número máximo definido, ou a rejeição da época completa quando o número de canais problemáticos ultrapassa um determinado critério de consenso. Deste modo, o AutoReject não se limita à exclusão de segmentos, integrando também uma estratégia de reparação seletiva, com o objetivo de reduzir a perda de dados e aumentar a reprodutibilidade do pré-processamento.

Um aspeto particularmente relevante do AutoReject é o facto de combinar interpretação simples com otimização automática. Embora internamente recorra a validação cruzada e técnicas de otimização para ajustar os limiares, a lógica do método continua assente numa métrica fisicamente intuitiva, a amplitude pico a pico, facilitando a leitura e auditoria das decisões tomadas. Além disso, na versão local, a reparação dos canais contaminados é feita por interpolação espacial, apoiada na geometria dos sensores, o que reforça o seu interesse em pipelines modernas de EEG/MEG.

Assim, o AutoReject afirma-se como uma solução particularmente relevante para a limpeza automática grosseira de segmentos contaminados, sobretudo em pipelines em que se pretende reduzir subjetividade e aumentar escalabilidade. No entanto, a literatura mostra também que o método funciona melhor como complemento de outras abordagens, nomeadamente da ICA, que permite atuar de forma mais específica sobre artefactos fisiológicos recorrentes, como EOG, ECG ou EMG.

2.4 Métodos híbridos

Os métodos híbridos têm assumido um papel cada vez mais relevante na remoção de artefactos em EEG, sobretudo pela tentativa de combinar as vantagens de diferentes famílias de métodos num mesmo pipeline de processamento. Em vez de depender exclusivamente de uma única técnica, estas abordagens recorrem frequentemente a combinações sequenciais de decomposição, separação de fontes, filtragem ou análise tempo-frequência, com o objetivo de

melhorar a eficácia da limpeza do sinal. Esta secção apresenta a lógica subjacente a estas abordagens e sintetiza as principais combinações híbridas descritas na literatura.

2.4.1 Fundamentação das abordagens híbridas

Os métodos híbridos surgiram como resposta às limitações dos métodos isolados na remoção de artefactos em EEG. Embora muitas técnicas convencionais e automáticas revelem bom desempenho em cenários específicos, raramente conseguem, por si só, lidar de forma igualmente eficaz com a diversidade de artefactos presentes no sinal e a sobreposição entre atividade neural e ruído. Neste contexto, tornou-se progressivamente claro que a combinação de métodos com propriedades complementares poderia oferecer melhores resultados do que a utilização de uma única técnica (Roy et al., 2021).

A lógica destas abordagens assenta, em geral, numa combinação sequencial de etapas. Numa primeira fase, aplica-se um método com função de preparação ou decomposição do sinal, procurando separar o EEG em componentes, modos ou sub-bandas que tornem a contaminação mais acessível à análise. Numa segunda fase, recorre-se a uma técnica de separação, filtragem ou classificação, responsável por identificar e remover de forma mais seletiva as componentes artefactuais. Esta organização em etapas permite explorar simultaneamente diferentes propriedades do sinal, como a estrutura temporal, espectral, espacial ou estatística, aumentando a probabilidade de distinguir entre atividade cerebral e ruído.

2.4.2 Principais combinações híbridas na literatura

A literatura mostra que os métodos híbridos podem assumir combinações bastante distintas, dependendo do tipo de sinal disponível e do artefacto que se pretende remover. De forma geral, as combinações mais exploradas resultam da junção entre técnicas de decomposição adaptativa, métodos de separação cega de fontes e abordagens de análise tempo-frequência. A escolha da combinação não é arbitrária, mas sim dependente do número de canais por sinal.

No caso dos sinais multicanal, a literatura mostra combinações particularmente relevantes entre ICA e WT, CCA e WT, SOBI e SWT ou ainda CCA e VMD. Estas abordagens foram sobretudo exploradas para a remoção de artefactos oculares e musculares, sendo frequente que diferentes combinações se revelem mais eficazes para diferentes tipos de ruído (X. Chen et al., 2016). Em termos gerais, os métodos que combinam wavelets com técnicas de separação de fontes tendem a beneficiar do facto de uma etapa efetuar uma separação mais grosseira das componentes, enquanto a outra atua como refinamento em bandas específicas (Mahajan & Morshed, 2013). Em artefactos oculares, por exemplo, foram propostas combinações como WT-ICA, WT-CCA e SOBI-SWT, tendo esta última sido reportada em alguns estudos como particularmente eficaz (X. Chen et al., 2016). Para artefactos musculares, a literatura aponta também para o interesse de combinações como CCA-WT e VMD-CCA, que procuram melhorar a preservação do EEG útil enquanto reduzem a contaminação de alta frequência (Q. Chen et al., 2021).

Nos sinais de canal único, as combinações híbridas seguem uma lógica algo diferente. Como não existe informação espacial entre canais, a estratégia mais comum passa por decompor primeiro o sinal em IMFs ou modos variacionais, criando uma representação multicomponente artificial, para depois se aplicar técnicas como ICA, CCA, MCCA, SOBI ou mesmo variantes mais recentes. Neste grupo destacam-se combinações como EEMD-CCA, EEMD-ICA, CEEMD-ICA, VMD-CCA e VMD-SOBI. Em termos globais, o EEMD-CCA surgiu durante vários anos como uma das combinações mais frequentemente reportadas, tanto para artefactos oculares como musculares, enquanto abordagens mais recentes, como CEEMD-ICA ou VMD-CCA, foram propostas com o objetivo de melhorar a robustez da decomposição e a eficácia da separação (Sweeney et al., 2012). Também neste contexto se observou a introdução de combinações mais sofisticadas, como MEMD-IVA, embora o seu custo computacional tenha limitado a aplicação prática (Xu et al., 2018).

Outro aspeto importante é que algumas combinações híbridas foram desenvolvidas com um alvo relativamente específico. Certas abordagens revelaram maior sucesso na remoção de artefactos oculares, enquanto outras foram pensadas sobretudo para artefactos musculares, cuja contaminação tende a ser mais difícil devido à sua maior dispersão espectral e sobreposição com atividade cerebral. Esta especialização ajuda a explicar por que razão a literatura apresenta

resultados por vezes distintos consoante o tipo de artefacto avaliado, o tipo de sinal e os critérios de desempenho utilizados.

2.5 Síntese crítica

Em síntese, o estado da arte evidencia que a remoção de artefactos em EEG tem evoluído de abordagens mais simples e dependentes de canais de referência para métodos cada vez mais orientados para decomposição, separação automática de fontes e combinação de técnicas. Os métodos baseados em canais de referência continuam úteis em contextos específicos, mas a sua aplicabilidade é limitada pela necessidade de sinais auxiliares adequados. Em contraste, as abordagens de separação cega de fontes, em particular a ICA e a CCA, mantêm um papel central na literatura, sobretudo pela sua capacidade de atuar diretamente sobre a estrutura multicomponente do EEG sem depender de referências externas.

Paralelamente, os métodos automáticos têm vindo a ganhar relevância, uma vez que permitem reduzir a subjetividade da inspeção manual e aumentar a reprodutibilidade do pré-processamento. Por sua vez, os métodos híbridos demonstram que a combinação de técnicas complementares pode aumentar a eficácia da remoção de artefactos, embora geralmente à custa de maior complexidade algorítmica, maior sensibilidade à parametrização e maior custo computacional. Assim, a literatura atual aponta não para a existência de uma solução universalmente superior, mas para a necessidade de selecionar estratégias em função do tipo de sinal, do tipo de artefacto e do equilíbrio pretendido entre eficácia, robustez e simplicidade de implementação.

3 Desenvolvimento

Dados e Sinais

Pipeline Base

ICA+ICLabel

AutoReject

Pipelines Híbridas

Protocolo de Avaliação

Nesta secção descreve-se, de forma organizada, como foram preparados os dados e como foram implementados e testados os pipelines de pré-processamento. Começa-se pela caracterização dos sinais usados e pelas suas particularidades mais relevantes para a análise. Em seguida, apresenta-se o pipeline base aplicado antes dos algoritmos, bem como a forma como foram implementados o ICA+ICLabel, o AutoReject e as duas versões híbridas. Por fim, define-se o protocolo de avaliação e comparação, combinando métricas, inspeção visual e tempo de execução para suportar a interpretação dos resultados.

3.1 Dados e Sinais Analisados

3.1.1 MNE Sample

Este sinal foi utilizado por ser um dataset amplamente documentado, com aquisição multimodal e boa qualidade global. Não existem informações clínicas do sujeito no contexto do tutorial analisado. O registo apresenta 59 canais EEG, 1 canal EOG, além de canais MEG e canais de estímulo. O sinal foi obtido com frequência de amostragem de 600,61 Hz e tem duração de aproximadamente 4 minutos e 38 segundos. O dataset também inclui informações sobre a filtragem e condicionamento aplicados durante a aquisição, o que é relevante para interpretar diferenças na PSD e no conteúdo espectral após o pré-processamento (Gramfort, 2010).

3.1.2 Sub-001

Este registo não inclui informação clínica do paciente no dataset usado. O sinal contém 16 canais EEG com frequência de amostragem de 500 Hz e duração aproximada de 13 minutos e 38 segundos. A meta-informação indica um passa-banda entre 0,01 e 80 Hz, porém, na inspeção realizada durante o desenvolvimento do pipeline, observou-se que essa filtragem não chegou a acontecer. Este intervalo de filtragem apresenta uma limitação relevante para reprodutibilidade e comparação justa entre sinais (Rankaduwa, 2025).

3.1.3 PN00-1 a PN00-4

Os quatro sinais pertencem ao mesmo paciente (PN00), 55 anos, sexo masculino, com 29 canais EEG, todos os sinais apresentam uma convulsão com localização temporal e com lateralização direita.

Os sinais têm frequência de amostragem de 512 Hz e seguem a montagem 10-20, sendo particularmente úteis por incluírem períodos ictais definidos, permitindo discutir não só a limpeza do mesmo, mas também a preservação de atividade neurológica relevante, ou seja, a capacidade de manter a assinatura temporal espectral associada ao evento (Detti et al., 2020)

Os intervalos ictais usados na avaliação foram:

- **PN00-1:** 1143-1213 s
- **PN00-2:** 1220-1274 s
- **PN00-3:** 765-825 s
- **PN00-4:** 1006-1080 s

3.1.4 Pré-condições e oportunidades dos datasets

Os datasets analisados apresentam diferenças estruturais relevantes que condicionam a forma como os algoritmos devem ser comparados, mas essas mesmas diferenças também criam oportunidades claras para avaliar o desempenho do pré-processamento de forma mais informativa. Em primeiro lugar, existe heterogeneidade na aquisição, os sinais diferem nas modalidades disponíveis, no número de canais 16 vs 29 vs 59 e na existência de filtragem e registos “online” descritos nos metadados. Estas discrepâncias afetam diretamente métricas dependentes do conteúdo espectral e dificultam comparações absolutas entre sinais, o que justifica a necessidade de definir etapas padrão antes de isolar o impacto real de cada algoritmo.

Em segundo lugar, o MNE sample oferece uma oportunidade particularmente valiosa, a presença de um canal EOG permite uma validação direta e visual da correção de artefactos oculares. Em vez de depender apenas de métricas como razões espectrais entre bandas ou de

inferências indiretas, é possível confirmar no domínio temporal se os eventos de elevada amplitude observados no EOG deixam de se manifestar ou passam a manifestar-se de forma atenuada nos canais frontais após a aplicação do pré-processamento. Isto torna o MNE sample um caso de referência útil para verificar, de forma prática, a eficácia do pipeline na remoção da componente ocular.

Por fim, os sinais PN00-1 a PN00-4 representam outra oportunidade central do estudo, por incluírem intervalos ictais bem definidos, permitem avaliar se os algoritmos não só reduzem artefactos, mas também preservam e idealmente melhoram a informação neurológica clinicamente interpretável. Esta característica permite discutir a qualidade do pré-processamento com foco no objetivo clínico que era detetar e caracterizar a convulsão, comparando de forma consistente a dinâmica pré-ictal e ictal após a limpeza. Assim, a análise deixa de ser apenas “quem limpa mais” e passa a ser “quem limpa sem destruir conteúdo útil”, que é precisamente o critério mais relevante num pipeline automático aplicado a EEG com intenção clínica.

3.2 Pipeline Base Padronizado

Para assegurar um pré-processamento tecnicamente sólido e consistente com boas práticas em EEG, foi definido um pipeline base padronizado composto por etapas que são, na prática, quase obrigatórias em qualquer fluxo de trabalho, ou seja, a verificação da montagem e das posições dos canais, referenciação e filtragem. Estas operações são fundamentais para garantir estabilidade do sinal, reduzir componentes indesejadas e preparar os dados para etapas subsequentes de correção (Gorjan et al., 2022). Além disso, este pipeline base é particularmente importante no contexto do ICA+ICLabel, uma vez que o desempenho do classificador depende diretamente de informação topográfica válida e de uma preparação espectral coerente (Pion-Tonachini et al., 2019). Como consequência natural, esta padronização também facilita a leitura e comparação dos efeitos dos algoritmos, mas o seu propósito principal é garantir que os dados respeitam pré-condições essenciais de pré-processamento antes da aplicação de métodos de limpeza.

3.2.1 Montagem e verificação das posições dos canais

A primeira etapa do baseline consiste em garantir que o sinal tem uma montagem de elétrodos válida, pois tanto a interpretação espacial do EEG como o desempenho do ICLabel dependem fortemente da informação topográfica. Na prática, verificou-se que nem todos os datasets continham canais com localização definida, o que comprometia a extração de features topográficas usadas pelo ICLabel.

Para este efeito, foi implementada uma função de validação que interrompe a execução caso existam canais EEG sem posição válida. Esta validação foi essencial para prevenir resultados artificiais causados por ausência de geometria dos sensores.

Assim, sempre que se aplicou o ICLabel, assegurou-se previamente que o sinal possuía montagem e posições consistentes, evitando que a classificação de componentes fosse influenciada por informação topográfica ausente ou errada.

3.2.2 Referenciação aplicada (CAR)

Após validação da montagem, foi aplicada a referenciação média comum através do MNE. Esta escolha foi intencional, pois ao evitar projeções, reduz-se o risco de introduzir alterações matemáticas adicionais que possam ser interpretadas como outliers pelo AutoReject ou perturbar a distribuição dos dados para o ICA. Além disso, o ICLabel foi concebido assumindo dados referenciados de forma consistente e a CAR constitui uma escolha padrão e altamente replicável.

3.2.3 Filtragem aplicada

A filtragem bandpass foi usada como parte do baseline por dois motivos principais. Em primeiro lugar, reduzir deriva lenta e componentes muito rápidas, pois não são relevantes para o EEG de

interesse. Em segundo lugar, garantir consistência espectral para comparação das métricas e para o comportamento do ICA+ICLabel. Como regra geral, adotou-se um passa-banda 1-100 Hz, aplicado com filtro FIR, firwin e fase zero, assegurando filtragem sem atraso de fase.

No entanto, no caso específico do sinal sub-001, foi adotada uma exceção. A filtragem foi ajustada para 1-80 Hz. A razão não foi uma limitação técnica do método, mas sim coerência metodológica com a filtragem “intended” descrita nos metadados. Apesar de, durante a análise, não terem surgido evidências claras de que o filtro online devesse ser aplicado de facto, a escolha de 1-80 Hz foi mantida como forma de alinhar o baseline com aquilo que o dataset declara como pré-condição esperada, evitando que a comparação fosse enviesada por adicionar conteúdo acima de 80 Hz que, teoricamente, não deveria existir nesse sinal.

3.3 ICA+ICLabel

O algoritmo ICA+ICLabel foi construído com o objetivo de produzir um método automático e reprodutível, mas deliberadamente conservador na remoção de componentes, procurando reduzir artefactos sem comprometer conteúdo cerebral potencialmente útil. Para isso, o pipeline foi desenhado em três pilares, sendo o primeiro uma decomposição ICA robusta e estável, uma rotulagem automática suportada por probabilidades e uma política de exclusão multi-label baseada em thresholds que privilegia a preservação do sinal.

A decomposição foi realizada com Infomax estendido, uma escolha comum em EEG por lidar bem com fontes não gaussianas típicas de artefactos e atividade neural. Para garantir consistência entre execuções e permitir comparações entre sinais, foi fixado um seed. O número de componentes foi definido de forma adaptativa através de $n_components=0.99$, retendo 99% da variância explicada, evitando impor um número rígido de ICs quando os datasets diferem em duração, ruído e qualidade.

A aplicação do ICLabel foi feita com extração explícita da matriz de probabilidades por classe, permitindo tomar decisões transparentes e auditáveis. Antes da rotulagem, foi incluída uma verificação automática da montagem, como foi falado na secção anterior, garantindo que todos

os canais EEG possuísem coordenadas válidas, condição importante para não degradar as features topográficas usadas pelo ICLabel.

A política de exclusão foi definida como multi-label conservadora, baseada no conjunto de thresholds Train Accuracy. Esta opção foi escolhida por ser a mais estável e consistente para automatização, reduzindo variações de decisão entre sinais com perfis de ruído diferentes. Na prática, uma componente só é removida quando pelo menos uma classe artefactual ultrapassa o seu limiar e, simultaneamente, brain e other não ultrapassam os respetivos thresholds. Assim, evita-se remover ICs “mistas” onde exista probabilidade relevante de atividade cerebral ou componentes ambíguas classificadas como “other”, reforçando a preservação de informação neurofisiológica. O sinal final é então reconstruído com `ica.apply(..., exclude=exclude_idx)`, mantendo registo das decisões e probabilidades associadas para suporte da análise.

3.4 *AutoReject*

O algoritmo AutoReject foi integrado como uma estratégia automática de correção local por epochs, com prioridade em reparar em vez de rejeitar segmentos. Esta opção foi deliberada, pois o objetivo do projeto é produzir um método automático que preserve o máximo de informação contínua e clinicamente interpretável. A rejeição de epochs introduz descontinuidades no sinal, tornando a reconstrução do raw menos fiel e, potencialmente, comprometendo interpretações temporais, como, por exemplo, em períodos ictais. Assim, a estratégia adotada assume que o AutoReject deve atuar sobretudo como um mecanismo de correção pontual, removendo artefactos através de interpolação de canais dentro de cada epoch, mas mantendo o sinal completo disponível para análise posterior.

Para permitir esta atuação, o raw é primeiro segmentado em epochs de duração fixa, mas com um cuidado adicional, a duração do epoch não é escolhida arbitrariamente. Foi implementada uma função que procura automaticamente uma duração próxima de 2 segundos, limitada entre 1 e 3 segundos, cujo número de amostras divide exatamente o comprimento total do sinal. Esta condição é importante porque garante que o processo de reconstrução posterior não cria desalinhamentos, ou seja, o sinal pode ser reconstruído de forma determinística, preservando o número total de amostras e evitando efeitos artificiais introduzidos por recortes ou padding.

Uma vez definidos os epochs, o AutoReject é configurado com uma grelha de parâmetros adaptativa, desenhada para manter o comportamento automático do método, seleção via validação cruzada, mas restringindo o espaço de procura a valores coerentes com a qualidade do sinal. Primeiro, estima-se um indicador de “sujidade” baseado numa medida robusta de amplitude peak-to-peak por epoch, onde se calcula a mediana por canal e limiar MAD. Este indicador corresponde à percentagem de epochs “extremos”, permitindo classificar o sinal como clean, medium ou dirty. Em seguida, a grelha de parâmetros é ajustada em função do número de canais EEG disponíveis e do nível de sujidade estimado. Para sinais mais limpos, a grelha é reduzida para evitar interpolação excessiva e acelerar a execução. Para sinais mais contaminados, a grelha é alargada dentro de limites razoáveis, aumentando a capacidade do método de tentar reparar mais canais por epoch sem depender de decisões rígidas definidas manualmente. Em todos os casos, o AutoReject mantém a lógica original, ou seja, selecionar automaticamente, por validação cruzada, a melhor combinação entre número de canais a interpolar e a eliminar.

Após o ajuste, é aplicada uma estratégia que garante que o output final mantém o tamanho do sinal original. Embora o AutoReject possa identificar epochs como irrecuperáveis e, em alguns cenários, removê-los da lista final, neste trabalho optou-se por reconstruir um conjunto de epochs com o mesmo número do original. Assim, os epochs considerados bons são substituídos pelas versões reparadas, enquanto os epochs marcados como maus são mantidos tal como estavam no sinal original. Esta decisão minimiza alterações artificiais em segmentos onde a interpolação poderia ser pouco fiável e, ao mesmo tempo, evita remover partes do sinal. Por fim, o sinal contínuo é reconstruído concatenando os epochs, obtendo um raw corrigido com dimensão idêntica ao original, já preparado para as fases seguintes de comparação ou integração com outros métodos.

3.5 Pipelines Híbridas

Nas pipelines híbridas, foram combinados os dois métodos AutoReject e ICA+ICLabel sem alterar a sua configuração interna, isto é, cada técnica foi aplicada exatamente com as estratégias e parâmetros descritos nas secções 3.3 e 3.4. O objetivo desta fase foi sim testar se a ordem de aplicação poderia explorar vantagens complementares, tal como sugerido pela literatura e observado empiricamente durante o desenvolvimento.

A pipeline AutoReject+ICA+ICLabel foi motivada diretamente pelas recomendações presentes na documentação e nas boas práticas associadas ao AutoReject, onde é sugerido que uma limpeza inicial de segmentos e canais extremos pode melhorar o desempenho e a estabilidade do ICA. Nesta lógica, o AutoReject atua primeiro como uma etapa de limpeza do ruído mais severo, reparando epochs com canais contaminados e sinalizando epochs irrecuperáveis, produzindo um sinal globalmente mais estável. Em seguida, o ICA+ICLabel funciona como um passo mais seletivo e dirigido, tal como um cirurgião decompondo o sinal em componentes independentes e removendo diretamente aquelas classificadas como artefactos, com base na política multi-label conservadora definida.

Por sua vez, a pipeline ICA+ICLabel+AutoReject surgiu como uma hipótese de trabalho baseada na observação sistemática dos resultados durante a fase de teste dos algoritmos. Verificou-se que o ICA+ICLabel, isoladamente, tinha um desempenho acima do esperado na remoção de artefactos, deixando frequentemente apenas resíduos localizados ou episódios pontuais de contaminação. Simultaneamente o AutoReject mostrou-se eficaz e conservador na interpolação de canais quando a contaminação é episódica. Assim, a ideia passou por primeiramente aplicar o ICA+ICLabel para reduzir drasticamente a carga global de artefactos e depois aplicar o AutoReject para atuar como um refinamento final, focado em reparar os poucos segmentos e até canais residualmente problemáticos, idealmente sem necessidade de intervenções agressivas.

Finalmente, a exploração de ambas as ordens foi essencial para discutir riscos e trade-offs. O principal perigo de colocar o AutoReject no fim passa por se correr o risco de o método interpolar canais que já estariam suficientemente limpos, introduzindo alterações desnecessárias e potencialmente degradando certas características do sinal em canais saudáveis. Por outro lado, colocar o AutoReject antes pode melhorar a estabilidade do ICA, mas também pode condicionar a decomposição se a interpolação inicial alterar relações espaciais finas entre canais. Por isso, estas pipelines híbridas foram exploradas como hipóteses complementares.

3.6 Protocolo de Avaliação e Métricas

A avaliação e comparação de pipelines de pré-processamento de EEG não podem assentar num único indicador, porque a qualidade final depende simultaneamente da redução efetiva de artefactos, da preservação de informação neurofisiológica relevante e da viabilidade prática do método. Assim, foi definido um protocolo de avaliação assente em três pilares complementares:

1. Métricas quantitativas;
2. Avaliação visual no domínio temporal e espectral;
3. Medição do tempo total de execução do pipeline.

3.6.1 Métricas Quantitativas

As métricas quantitativas foram organizadas em três grupos, alinhados com os artefactos mais frequentes em EEG, os oculares, os musculares e o ruído de linha (Ille et al., 2024). Em todos os casos, o cálculo espectral foi suportado por PSD estimado pelo método de Welch e por integração numérica da potência nas bandas de interesse, garantindo consistência entre sinais e algoritmos.

Para a avaliação ocular foram calculadas as razões Delta/Beta, Delta/Alpha, Theta/Beta e Theta/Alpha em canais frontais. Estas razões funcionam como aproximações instrumentais de contaminação ocular, pois eventos oculares tendem a manifestar-se como perturbações de baixa frequência, com maior expressão na região frontal, alterando a distribuição de potência nessas bandas e nessa topografia (Pion-Tonachini et al., 2019). Assim, reduções consistentes destas razões após o pré-processamento são interpretadas como indício de atenuação de artefactos oculares, embora a leitura seja sempre relativa e não uma medida clínica direta. Para garantir consistência na análise, o cálculo foi efetuado com base no PSD estimado por Welch, integrando a potência por banda de integração numérica no intervalo de frequências correspondente.

Para a componente muscular foram utilizadas métricas centradas no conteúdo de alta frequência, onde a contaminação EMG tende a ter maior impacto (Muthukumaraswamy, 2013). Em concreto, calcularam-se as razões Beta/Gamma e Gamma/Alpha, a potência total acima de 35 Hz e o declive $1/f$ estimado por regressão linear em escala log-log numa banda larga. Para minimizar enviesamento por ruído de linha, o cálculo do declive $1/f$ excluiu as bandas em torno de 50/60 Hz. Estas métricas foram calculadas apenas em canais temporais, uma vez que, em EEG de couro cabeludo, a contaminação muscular costuma ser mais evidente em regiões laterais e temporais devido à proximidade de grupos musculares como o temporalis e o masseter (Yilmaz et al., 2019). As razões Beta/Gamma e Gamma/Alpha permitem quantificar alterações relativas no balanço entre energias em bandas médias e altas. Adicionalmente, a potência total acima dos 35 Hz funciona como marcador mais direto de energia de alta frequência. Já o $1/f$ slope resume o comportamento global do espectro, uma vez que a presença de EMG tende a “achatar” o decaimento espectral. Assim sendo, alterações coerentes do declive no sentido deste se tornar mais negativo, acompanhadas da redução da $P > 35$ Hz e das razões espectrais das bandas cerebrais são indicações da atenuação de EMG residual. Ainda assim, estas métricas devem ser interpretadas como indicadores instrumentais.

Para o ruído de linha foi implementada uma métrica baseada na razão entre a potência numa banda estreita centrada em 50 Hz ou 60 Hz e a potência em bandas adjacentes. O objetivo foi detetar alterações específicas no entorno destas frequências, permitindo identificar se um pipeline reduz, mantém ou realça componentes estreitas associadas à rede elétrica. Importa, no entanto, reconhecer que variações nesta razão podem refletir alterações relativas do espectro induzidas por outros passos do pipeline. Por esse motivo, esta métrica foi sempre interpretada em conjunto com a inspeção do PSD.

3.6.2 Análise Visual no domínio temporal e espectral

Além das métricas referidas anteriormente, foi assumida como requisito metodológico a avaliação visual sistemática do sinal no domínio do tempo e da frequência. No domínio temporal, esta inspeção permite confirmar artefactos residuais evidentes e identificar

alterações inesperadas em canais específicos. No domínio espectral, a análise do PSD permite verificar se a supressão de alta frequência ocorre de forma coerente, se o ruído de linha permanece evidente e se a distribuição global de energia pelas bandas EEG se mantém compatível com uma interpretação fisiológica plausível.

3.6.3 Preservação de informação clinicamente interpretável

A avaliação foi também orientada para a preservação de informação neurológica interpretável, para isso foi calculado o Brain Symmetry Index (BSI) em janelas não sobrepostas de 10 segundos, comparando médias no intervalo pré-ictal e no intervalo ictal entre as bandas de 0,5 e 30 Hz. Neste trabalho, os pares de canais considerados foram os canais temporais esquerdos e direitos, dado que os episódios analisados apresentam uma localização temporal direita. A motivação é simples, durante uma crise focal temporal direita, espera-se que ocorram alterações rítmicas ou aumentos de potência em determinadas bandas no hemisfério afetado, o que tende a aumentar a assimetria entrelados (Perucca et al., 2013). Assim, o BSI foi usado como uma medida de assimetria espectral entre as regiões temporais direita e esquerda. O BSI foi calculado por janela da seguinte forma ilustrada pela equação:

$$BSI_a = \frac{\sum_{f=f_{min}}^{f_{max}} |P_R(f) - P_L(f)|}{\sum_{f=f_{min}}^{f_{max}} |P_R(f) + P_L(f)|}$$

- $f_{max} = 30$ Hz;
- $f_{min} = 0,5$ Hz;
- $P_R(f)$ = Potência espectral média dos canais temporais do lado direito para a frequência f ;
- $P_L(f)$ = Potência espectral média dos canais temporais do lado esquerdo para a frequência f .

O objetivo foi verificar se o pipeline preserva ou não diferenças espectrais potencialmente relevantes e se mantém separabilidade entre estados pré-ictal e ictal. Isto é essencial porque

um algoritmo pode reduzir fortemente artefactos e, ainda assim, degradar padrões neurológicos que sustentam o objetivo clínico do sinal.

3.6.4 *Custo Computacional*

O custo computacional foi integrado como critério explícito, medido como tempo total de execução do pipeline. Esta opção é particularmente relevante em contextos de automatização e em pipelines com validação cruzada interna, onde aumentos por ordem de grandeza podem inviabilizar o processamento de múltiplos exames em tempo útil.

3.6.5 *Critérios de decisão final*

A decisão final foi orientada por um equilíbrio entre:

- Qualidade de limpeza;
- Preservação de conteúdo clinicamente interpretável
- Eficiência computacional

4 Resultados

Resultados por Sinal
Comparação Global

Nesta secção são apresentados os resultados obtidos com a aplicação dos diferentes pipelines de pré-processamento aos sinais em estudo, integrando métricas quantitativas de artefacto, inspeção visual no domínio temporal e indicadores de execução, com o objetivo de caracterizar comparativamente o desempenho de cada algoritmo.

4.1 Resultados por Sinal

Nesta secção apresentam-se os resultados obtidos para cada um dos sinais analisados, organizados de forma individual para permitir uma leitura estruturada do comportamento dos diferentes pipelines em contextos distintos. Em cada subsecção são apresentados, sucessivamente, os resultados das métricas quantitativas de artefacto, a inspeção visual no domínio temporal e uma síntese dos principais indicadores de execução, incluindo tempo de processamento, parâmetros seleccionados, epochs assinalados como maus e, quando aplicável, o número de componentes ICA excluídas. Esta organização permite descrever, para cada registo, não só o impacto dos algoritmos na redução de artefactos, mas também o seu comportamento operacional e a preservação de características relevantes do sinal.

4.1.1 MNE Sample

O sinal MNE sample foi incluído na análise por constituir um registo de referência, com boa qualidade global e estrutura multimodal, permitindo avaliar de forma controlada o comportamento dos diferentes pipelines de pré-processamento. Nesta subsecção apresentam-se, em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 1 - Métricas dos Algoritmos para o sinal MNE.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	4.0751→2.4733	4.0751→1.5613	4.0751→1.5789	4.0751→1.0754
Ocular	Delta/Alpha	4.9651→3.4060	4.9651→0.5444	4.9651→0.5516	4.9651→0.6419
Ocular	Theta/Beta	1.1830→0.9105	1.1830→2.4160	1.1830→2.4201	1.1830→1.6073
Ocular	Theta/Alpha	1.4385→1.2089	1.4385→0.8415	1.4385→0.8417	1.4385→0.8913
Muscular	Beta/Gamma	2.1466→2.3104	2.1466→3.5388	2.1466→3.6359	2.1466→3.2886

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Muscular	Gamma/Alpha	1.1232→0.5658	1.1232→0.2402	1.1232→0.2241	1.1232→0.3015
Muscular	Power>35Hz	1.848e-11→8.86	1.848e-11→3.98	1.848e-11→3.30	1.848e-11→4.27
		6e-12	5e-12	3e-12	7e-12
Muscular	1/f slope	-0.7836→-0.991	-0.7836→-1.409	-0.7836→-1.494	-0.7836→-1.416
		4	3	8	7

A inspeção visual no domínio temporal dos traçados mostra que, em janelas específicas assinaladas, como por exemplo, aos 81 segundos nos canais 25 e 51, o pipeline ICA+ICLabel+AutoReject evidencia atenuação de eventos residuais que ainda se observam no ICA+ICLabel, observar Figura 2. Em contraste, ao analisar os outputs de AutoReject e AutoReject+ICA+ICLabel, observa-se que a introdução do passo ICA+ICLabel constitui uma vantagem clara na redução de eventos residuais. No entanto, não chega para atingir o mesmo nível de atenuação observado nos dois pipelines onde a técnica inicial é ICA+ICLabel.




Figura 2- Comparação entre os sinais processados por ICA+ICLabel+AutoReject (esquerda) e ICA+ICLabel (direita), no intervalo [76,86] s. As regiões assinaladas mostram atenuação de artefactos residuais após a aplicação do AutoReject.

A Tabela 2 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal MNE sample, incluindo o tempo total de processamento, os parâmetros

selecionados pelo AutoReject, o número de epochs assinalados como maus e o número de componentes ICA ajustadas e excluídas.

Tabela 2 - Métricas de execução dos algoritmos no sinal MNE sample.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs sinalizados (bad/total)	ICs selecionadas/excluídas
AutoReject	3 min	0,60; 8	2 / 139	—
ICA+ICLabel	40 s	—	—	16 / 33
ICA+ICLabel+Auto Reject	4 min	0,60; 8	2 / 139	16 / 33
AutoReject+ICA+ICLabel	4 min	0,60; 8	2 / 139	14 / 35

Em conjunto, os resultados apresentados para o sinal MNE sample permitem identificar diferenças claras entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do comportamento durante a execução, servindo este sinal como referência inicial para a análise dos restantes registos.

4.1.2 Sub00-1

O sinal sub-001 apresenta características distintas do registo MNE, nomeadamente um menor número de canais e uma contaminação artefactual mais expressiva, o que o torna adequado para comparar o comportamento dos diferentes pipelines num contexto menos controlado. Nesta subsecção apresentam-se, em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 3 - Métricas do sinal Sub00-1.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	30,2430 → 25,8805	30,2430 → 4,4026	30,2430 → 4,3100	30,2430 → 3,7718
Ocular	Delta/Alpha	18,7767 → 17,1470	18,7767 → 2,6590	18,7767 → 2,5087	18,7767 → 3,3067
Ocular	Theta/Beta	3,1795 → 2,8150	3,1795 → 1,3939	3,1795 → 1,4087	3,1795 → 1,1692
Ocular	Theta/Alpha	1,9908 → 1,8630	1,9908 → 0,8315	1,9908 → 0,8220	1,9908 → 0,9334
Muscular	Beta/Gamma	2,4465 → 2,4968	2,4465 → 2,3220	2,4465 → 2,2885	2,4465 → 2,3646
Muscular	Gamma/Alpha	0,2711 → 0,2672	0,2711 → 0,3054	0,2711 → 0,3132	0,2711 → 0,3110
Muscular	Power>35Hz	2,789e-12 → 2,765e-12	2,789e-12 → 2,485e-12	2,789e-12 → 2,964e-12	2,789e-12 → 2,767e-12
Muscular	1/f slope	-1,3127 → -1,3262	-1,3127 → -1,2035	-1,3127 → -1,1914	-1,3127 → -1,2148
Ruído de Linha	60 Hz	0,9301 → 0,9795	0,9301 → 0,9769	0,9301 → 0,9799	0,9301 → 0,9822

A inspeção visual no domínio temporal mostra que o ICA+ICLabel, quando aplicado isoladamente, produz um traçado globalmente mais estável, ainda que com a permanência de artefactos pontuais em instantes específicos. O algoritmo ICA+ICLabel+AutoReject, consegue atenuar alguns desses eventos residuais, mas também surgem situações em que a interpolação introduz distorções noutros canais, por exemplo, no intervalo de 27 a 32 s, com alterações visíveis em canais temporais como TP9/TP10, observar Figura 3. Em contraste, os pipelines que aplicam AutoReject como primeira etapa não atingem o mesmo nível de limpeza global observado com o ICA+ICLabel, embora o AutoReject+ICA+ICLabel represente uma melhoria clara face ao AutoReject isolado, evidenciando o contributo do passo ICA+ICLabel na redução de contaminação residual.




Figura 3 - Comparação entre os sinais processados por ICA+ICLabel+AutoReject (direita) e ICA+ICLabel (esquerda), no intervalo [27,32] s. As regiões assinaladas mostram atenuação e ampliação de artefactos residuais após a aplicação do AutoReject.

A Tabela 4 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal sub-001, incluindo o tempo total de processamento, os parâmetros seleccionados pelo AutoReject, o número de epochs assinalados como maus e o número de componentes ICA ajustadas e excluídas.

Tabela 4 - Métricas de execução dos algoritmos no sinal Sub00-1.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs sinalizados (bad/total)	ICs seleccionadas/ excluídas
AutoReject	1 min 30 s	0,60; 2	39 / 320	—
ICA+ICLabel	1 min	—	—	4 / 12
ICA+ICLabel+AR	2 min	0,60; 3	5 / 320	4 / 12
AR+ICA+ICLabel	2 min 18 s	0,60; 2	44 / 320	3 / 13

No conjunto, os resultados obtidos para o sinal sub-001 evidenciam diferenças claras entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do

comportamento durante a execução, confirmando a utilidade deste registo para avaliar algoritmos em condições de maior contaminação artefactual.

4.1.3 PN00-1

O sinal PN00-1 corresponde a um registo clínico com atividade ictal identificada, o que lhe confere particular relevância na avaliação dos pipelines, não apenas pela redução de artefactos, mas também pela preservação de conteúdo neurológico interpretável. Nesta subsecção apresentam-se, em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 5- Métricas do sinal PN00-1.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	21.0081→18.806 1	21.0081→6.7123	21.0081→6.6441	21.0081→7.5620
Ocular	Delta/Alpha	43.2233→39.944 5	43.2233→15.108 4	43.2233→14.653 8	43.2233→15.883 4
Ocular	Theta/Beta	2.2508→1.9873	2.2508→1.0845	2.2508→1.1102	2.2508→1.2803
Ocular	Theta/Alpha	4.6758→4.2572	4.6758→2.4148	4.6758→2.4155	4.6758→2.6832
Muscular	Beta/Gamma	1.2713→1.2759	1.2713→1.5591	1.2713→1.5764	1.2713→1.5816
Muscular	Gamma/Alpha	2.8255→2.7432	2.8255→2.2386	2.8255→2.1060	2.8255→2.0910
Muscular	Power>35Hz	4.125e-11→3.98 5e-11	4.125e-11→1.69 9e-11	4.125e-11→1.39 8e-11	4.125e-11→1.61 7e-11
Muscular	1/f slope	-0.2194→-0.222 9	-0.2194→-0.454 3	-0.2194→-0.463 5	-0.2194→-0.489 3
Ruído de Linha	50Hz	0.8078→0.8661	0.8078→1.3181	0.8078→1.1025	0.8078→1.4056

A inspeção visual no domínio temporal evidencia diferenças sobretudo na forma como os pipelines lidam com eventos transitórios. Neste sinal, a aplicação do AutoReject antes do ICA+ICLabel não reproduz o mesmo grau de estabilização observado nos pipelines em que o ICA

atua primeiro, embora apresente melhorias em comparação com o AutoReject isolado. Ao comparar diretamente ICA+ICLabel com ICA+ICLabel+AutoReject, a etapa adicional de AutoReject traduz-se numa atenuação de artefactos pontuais e numa maior estabilização de canais com ruído persistente, por exemplo, nos canais FC2 e T6, observar a Figura 4. Por fim, na janela ictal, não se identificam alterações visuais relevantes atribuíveis ao AutoReject, mantendo-se o padrão temporal associado ao evento, o que sugere que a etapa adicional não introduz perturbações macroscópicas na dinâmica ictal observável no traçado.




Figura 4 - Comparação entre os sinais processados por ICA+ICLabel+AutoReject (direita) e ICA+ICLabel (esquerda), no intervalo [59,69] s. As regiões assinaladas mostram atenuação de artefactos residuais após a aplicação do AutoReject.

A Tabela 6 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal PN00-1, incluindo o tempo total de processamento, os parâmetros seleccionados pelo AutoReject, o número de epochs assinalados como maus, o número de componentes ICA ajustadas e excluídas, bem como a variação do Δ BSI antes e depois do pré-processamento.

Tabela 6 - Métricas de execução dos algoritmos no sinal PN00-1.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs total	ICs excluídas /total	Δ BSI (antes / depois)
AutoReject	15	0,60; 4	553 / 1344	—	0,1569 → 0,1610
ICA+ICLabel	10	—	—	11 / 24	0,1569 → 0,2550
ICA+ICLabel+AR	27	0,70; 6	175 / 1344	11 / 24	0,1569 → 0,2329
AR+ICA+ICLabel	33	0,60; 4	553 / 1344	12 / 25	0,1569 → 0,2753

No conjunto, os resultados obtidos para o sinal PN00-1 evidenciam diferenças claras entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do comportamento durante a execução, mostrando simultaneamente o impacto do pré-processamento na remoção de artefactos e na preservação da informação associada à janela ictal.

4.1.4 PN00-2

O sinal PN00-2 corresponde também a um registo clínico com atividade ictal identificada, permitindo avaliar os pipelines não só na redução de artefactos, mas também na preservação de padrões neurológicos potencialmente relevantes. Nesta subsecção apresentam-se, em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 7 - Métricas do sinal PN00-2.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	12,0747→10,78 49	12,0747→9,166 6	12,0747→8,917 6	12,0747→9,748 0
Ocular	Delta/Alpha	17,9818→16,17 46	17,9818→12,19 90	17,9818→11,81 07	17,9818→12,86 14
Ocular	Theta/Beta	1,6125→1,6052	1,6125→1,7868	1,6125→1,7810	1,6125→1,7591
Ocular	Theta/Alpha	2,4561→2,4518	2,4561→2,3248	2,4561→2,3241	2,4561→2,3213
Muscular	Beta/Gamma	1,5891→1,6145	1,5891→2,5953	1,5891→2,6322	1,5891→1,8945
Muscular	Gamma/Alpha	1,7691→1,6961	1,7691→0,7007	1,7691→0,6588	1,7691→0,9599
Muscular	Power>35Hz	4,421e-11→4,27 3e-11	4,421e-11→1,66 8e-11	4,421e-11→1,59 4e-11	4,421e-11→2,1 13e-11
Muscular	1/f	-0,2474→-0,262 8	-0,2474→-0,782 3	-0,2474→-0,801 3	-0,2474→-0,45 07
Ruído de Linha	Ruído de linha	0,8193→0,8540	0,8193→0,6794	0,8193→0,6787	0,8193→0,7343

A inspeção visual no domínio temporal mostra que os algoritmos atuam de forma complementar neste sinal. A aplicação do AutoReject após o ICA+ICLabel conduz a uma atenuação adicional de artefactos residuais, sobretudo eventos de alta amplitude e baixa frequência, e também de episódios em que canais com ruído de baixa amplitude e alta frequência são parcialmente recuperados por interpolação. Ao comparar ICA+ICLabel+AutoReject com AutoReject+ICA+ICLabel, observa-se que ambos conseguem melhorar o traçado, mas por vias diferentes. No fundo, há segmentos em que um corrige artefactos que o outro não corrige, resultando em sinais visualmente próximos, embora diferentes, observar a Figura 5.




Figura 5 - Comparação entre os sinais processados por ICA+ICLabel+AutoReject (direita) e AutoReject+ICA+ICLabel (esquerda), no intervalo [102,111] s. As regiões assinaladas mostram as diferenças de atuação dos dois algoritmos.

A mesma lógica surge na comparação entre os algoritmos isolados. O AutoReject mostra maior capacidade para atenuar artefactos lentos e de grande amplitude, enquanto o ICA+ICLabel reduz com mais evidência ruído rápido e de baixa amplitude. Isto pode ser observado, respetivamente, nos canais C3 e FC2 na Figura 6.




Figura 6 - Comparação entre os sinais processados por AutoReject (direita) e ICA+ICLabel (esquerda), no intervalo [204,212] s. As regiões assinaladas mostram as diferenças de atuação entre os dois algoritmos.

A Tabela 8 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal PN00-2, incluindo o tempo total de processamento, os parâmetros selecionados pelo AutoReject, o número de epochs assinalados como maus, o número de componentes ICA ajustadas e excluídas, bem como a variação do delta BSI antes e depois do pré-processamento.

Tabela 8 - Métricas de execução dos algoritmos no sinal PN00-2.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs Total	ICs excluídas /total	Δ BSI (antes / depois)
AutoReject	13	0,80; 6	111 / 1151	—	0,1720 → 0,1715
ICA+ICLabel	6,4	—	—	9 / 24	0,1720 → 0,2518
ICA+ICLabel+AR	15	0,60; 8	139 / 1151	9 / 24	0,1720 → 0,2503
AR+ICA+ICLabel	16,1	0,80; 6	111 / 1151	9 / 25	0,1720 → 0,2608

No conjunto, os resultados obtidos para o sinal PN00-2 mostram diferenças claras entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do comportamento durante a execução, evidenciando simultaneamente o impacto do pré-processamento na remoção de artefactos e na preservação da dinâmica associada à atividade ictal.

4.1.5 PN00-3

O sinal PN00-3 corresponde a outro registo clínico com atividade ictal identificada, permitindo analisar os diferentes pipelines tanto na redução de artefactos como na preservação de características temporais e espectrais relevantes do evento. Nesta subsecção apresentam-se,

em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 9 - Métricas do sinal PN00-1.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	11,0200→9,5122	11,0200→4,1704	11,0200→4,2243	11,0200→4,8373
Ocular	Delta/Alpha	30,5051→26,840 4	30,5051→12,853 2	30,5051→13,054 2	30,5051→16,059 9
Ocular	Theta/Beta	1,1840→1,0052	1,1840→0,5607	1,1840→0,5662	1,1840→0,6153
Ocular	Theta/Alpha	3,2798→2,8481	3,2798→1,6976	3,2798→1,7186	3,2798→1,9735
Muscular	Beta/Gamma	1,0134→1,0179	1,0134→1,0284	1,0134→1,0443	1,0134→1,1022
Muscular	Gamma/Alpha	4,6818→4,5785	4,6818→3,3330	4,6818→3,2534	4,6818→3,4534
Muscular	Power>35Hz	1,693e-10→1,62 7e-10	1,693e-10→1,24 3e-11	1,693e-10→1,23 8e-11	1,693e-10→3,16 5e-11
Muscular	1/f slope	0,0607→0,0567	0,0607→0,0695	0,0607→0,0537	0,0607→-0,0385
Ruído de Linha	50Hz	0,5449→0,5556	0,5449→0,5916	0,5449→0,5910	0,5449→0,5977

A inspeção visual no domínio temporal mostra diferenças claras entre os pipelines. O AutoReject+ICA+ICLabel apresenta menor capacidade de limpeza global do que os pipelines em que o ICA+ICLabel atua primeiro. Ainda assim, quando comparado diretamente com o AutoReject isolado, observa-se uma redução mais evidente de artefactos residuais, o que confirma a utilidade da etapa ICA+ICLabel mesmo nesta ordem de aplicação. A comparação principal centra-se, por isso, entre ICA+ICLabel e ICA+ICLabel+AutoReject. Entre estes dois, a aplicação posterior do AutoReject melhora o sinal em dois aspetos principais. Por um lado, estabiliza canais contaminados por ruído de baixa amplitude e alta frequência, como se observa logo nos instantes iniciais em F4 e C4 a partir da Figura 7. Por outro, contribui também para a atenuação de artefactos pontuais de elevada amplitude e baixa frequência. Ao longo da janela ictal, ambos os algoritmos mantêm identificáveis o início e o fim do período de crise, sem perda visual dessa informação no traçado.




Figura 7 - Comparação entre os sinais processados por ICA+ICLabel+AutoReject (direita) e ICA+ICLabel (esquerda), no intervalo [0,10] s. As regiões assinaladas mostram atenuação de artefactos residuais após a aplicação do AutoReject.

A Tabela 10 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal PN00-3, incluindo o tempo total de processamento, os parâmetros seleccionados pelo AutoReject, o número de epochs assinalados como maus, o número de componentes ICA ajustadas e excluídas, bem como a variação do delta BSI antes e depois do pré-processamento.

Tabela 10 - Métricas de execução dos algoritmos no sinal PN00-3.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs total	ICs excluídas /total	Δ BSI (antes / depois)
AutoReject	16	0,60; 8	702 / 1544	—	0,1938 → 0,1764
ICA+ICLabel	5,1	—	—	14 / 21	0,1938 → 0,1571

Pipeline	Tempo total	Parâmetros AutoReject	Epochs total	ICs excluídas /total	Δ BSI (antes / depois)
ICA+ICLabel+AR	20	0,60; 8	494 / 1544	14 / 21	0,1938 → 0,1599
AR+ICA+ICLabel	25	0,60; 8	702 / 1544	12 / 22	0,1938 → 0,2034

No conjunto, os resultados obtidos para o sinal PN00-3 mostram diferenças nítidas entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do comportamento durante a execução, permitindo avaliar simultaneamente a capacidade de limpeza do sinal e a preservação da informação associada à janela ictal.

4.1.6 PN00-4

O sinal PN00-4 corresponde a mais um registo clínico com atividade ictal identificada, permitindo avaliar o desempenho dos diferentes pipelines tanto na redução de artefactos como na preservação de padrões temporais e espectrais relevantes para a interpretação do evento. Nesta subsecção apresentam-se, em primeiro lugar, as métricas quantitativas de artefacto obtidas para os quatro algoritmos testados.

Tabela 11 – Métricas do sinal PN00-4.

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Ocular	Delta/Beta	23,1406→19,7458	23,1406→9,2406	23,1406→9,8858	23,1406→10,6930
Ocular	Delta/Alpha	45,9726→41,4560	45,9726→22,3107	45,9726→21,9173	45,9726→24,6457
Ocular	Theta/Beta	2,2762→1,9806	2,2762→1,3414	2,2762→1,3911	2,2762→1,5088
Ocular	Theta/Alpha	4,5207→4,1267	4,5207→2,7538	4,5207→2,7393	4,5207→2,9921
Muscular	Beta/Gamma	1,3002→1,3210	1,3002→1,8022	1,3002→1,8295	1,3002→1,5458

Grupo	Métrica	AutoReject	ICA+ICLabel	ICA+ICLabel+AR	AR+ICA+ICLabel
Muscular	Gamma/Alpha	3,0000→2,7178	3,0000→2,0104	3,0000→2,0476	3,0000→2,2439
Muscular	Power>35Hz	4,790e-11→4,167e-11	4,790e-11→1,022e-11	4,790e-11→9,677e-12	4,790e-11→1,439e-11
Muscular	1/f slope	-0,1661→-0,1778	-0,1661→-0,3838	-0,1661→-0,3919	-0,1661→-0,3307
Ruído de Linha	50 Hz	0,7473→0,8088	0,7473→0,9300	0,7473→0,9664	0,7473→0,9207

A inspeção visual no domínio temporal evidencia diferenças claras entre os pipelines. O ICA+ICLabel+AutoReject apresenta, em vários segmentos, uma atenuação adicional de artefactos que permanecem após o ICA+ICLabel isolado, nomeadamente em canais com contaminação muscular mais evidente e em episódios de baixa frequência e elevada amplitude, o que se traduz numa maior estabilização local do traçado. Esta vantagem é visível, por exemplo, em canais como F7, Fz e P3, onde a aplicação posterior do AutoReject reduz a expressão de artefactos residuais. Contudo, esta melhoria não é uniforme em todo o sinal, pois em alguns intervalos, como entre 96 e 98 segundos no canal F9, e novamente entre 140 e 142 s, a intervenção do AutoReject introduz atividade de elevada amplitude e alta frequência, alterando a morfologia local do traçado, observar a Figura 8. Ainda assim, de forma global, a aplicação do AutoReject após o ICA+ICLabel permitiu remover artefactos que não tinham sido totalmente eliminados pelo ICA+ICLabel isolado. Por contraste, o AutoReject+ICA+ICLabel manteve-se abaixo do nível de limpeza observado nos outros dois pipelines principais, embora tenha evidenciado uma melhoria clara quando comparado com o AutoReject isolado.




Figura 8 - Comparação entre os sinais processados por ICA+ICLabel+AutoReject (direita) e ICA+ICLabel (esquerda), no intervalo [94,104] s. As regiões assinaladas mostram atenuação e ampliação de artefactos residuais após a aplicação do AutoReject

A Tabela 12 apresenta uma síntese dos principais indicadores de execução dos quatro pipelines aplicados ao sinal PN00-4, incluindo o tempo total de processamento, os parâmetros seleccionados pelo AutoReject, o número de epochs assinalados como maus, o número de componentes ICA ajustadas e excluídas, bem como a variação do Δ BSI antes e depois do pré-processamento.

Tabela 12 - Métricas de execução dos algoritmos no sinal PN00-4.

Pipeline	Tempo total	Parâmetros AutoReject	Epochs total	ICs excluídas /total	Δ BSI (antes / depois)
AutoReject	13	0,60; 6	340 / 1051	—	0,1671 → 0,1702
ICA+ICLabel	6,7	—	—	13 / 22	0,1671 → 0,2227

Pipeline	Tempo total	Parâmetros AutoReject	Epochs total	ICs excluídas /total	Δ BSI (antes / depois)
ICA+ICLabel+AR	15	0,80; 6	90 / 1051	13 / 22	0,1671 → 0,1607
AR+ICA+ICLabel	18,5	0,60; 6	340 / 1051	12 / 24	0,1671 → 0,2054

No conjunto, os resultados obtidos para o sinal PN00-4 evidenciam diferenças claras entre os pipelines, tanto ao nível das métricas quantitativas como da inspeção visual e do comportamento durante a execução, permitindo avaliar simultaneamente a eficácia da remoção de artefactos e a preservação de características relevantes da atividade ictal.

4.2 Comparação Global entre Algoritmos

Após a apresentação dos resultados por sinal, torna-se possível realizar uma leitura transversal do comportamento dos diferentes pipelines de pré-processamento. Esta secção reúne os principais resultados obtidos ao longo dos seis registos analisados, com foco em quatro dimensões complementares. A síntese quantitativa das métricas de artefacto, a leitura global do ruído de linha com apoio do PSD, a comparação visual dos sinais no domínio temporal e a síntese operacional de execução. O objetivo é identificar os padrões que se repetem entre sinais e algoritmos, destacando os aspetos mais relevantes para a interpretação global do desempenho de cada abordagem.

4.2.1 Síntese quantitativa das métricas de artefacto

Considerando o conjunto dos seis sinais analisados, as métricas quantitativas mostram um padrão global relativamente estável. Na componente ocular, o AutoReject isolado tende a

produzir reduções mais moderadas nas razões frontais, enquanto os pipelines que incluem ICA+ICLabel apresentam, de forma consistente, reduções mais acentuadas nas métricas baseadas em Delta/Beta, Delta/Alpha e, na maioria dos sinais, também nas razões com Theta. Entre estes, ICA+ICLabel e ICA+ICLabel+AutoReject surgem frequentemente com resultados muito próximos entre si, enquanto AutoReject+ICA+ICLabel mantém a tendência global, mas com valores finais ligeiramente superiores. Em termos globais, as métricas oculares apontam assim para um contributo dominante do bloco ICA+ICLabel na redução da componente ocular residual, com ganhos adicionais do AutoReject sobretudo marginais e dependentes do sinal.

Na componente muscular, o comportamento global também distingue claramente o AutoReject isolado dos pipelines com ICA+ICLabel. De forma geral, o AutoReject produz alterações mais pequenas e menos consistentes nos indicadores temporais de alta frequência, ao passo que os pipelines com ICA+ICLabel evidenciam reduções mais marcadas de Power>35 Hz e de Gamma/Alpha, acompanhadas, na maioria dos sinais, por alterações coerentes em Beta/Gamma e no 1/f slope. Tal como nas métricas oculares, ICA+ICLabel e ICA+ICLabel+AutoReject tendem a apresentar resultados muito próximos, com o pipeline híbrido a mostrar por vezes um efeito ligeiramente mais acentuado em alguns indicadores. O AutoReject+ICA+ICLabel acompanha a mesma direção global, mas de forma menos uniforme, surgindo em vários sinais com alterações intermédias entre o AutoReject isolado e os pipelines em que o ICA+ICLabel atua primeiro.

Em conjunto, a leitura quantitativa das métricas de artefacto mostra que os maiores deslocamentos nas componentes ocular e muscular estão, de forma geral, associados aos pipelines que incluem ICA+ICLabel, enquanto o AutoReject isolado apresenta um impacto mais limitado nestes indicadores. Dentro desse grupo, a aplicação posterior do AutoReject tende a manter o padrão já obtido pelo ICA+ICLabel, introduzindo apenas variações adicionais de menor magnitude.

4.2.2 Ruído de linha: leitura global das métricas e do PSD

A análise global do ruído de linha mostrou que a utilidade das métricas de 50/60 Hz depende fortemente do sinal em causa e, sobretudo, da existência real de contaminação por rede elétrica no registo. No MNE sample, esta métrica revelou-se pouco informativa, uma vez que o sinal não apresentava evidência relevante de ruído de linha, pelo que não foi utilizada como elemento diferenciador entre pipelines. Nos restantes sinais, a contaminação relevante surgiu de forma localizada. No sub00-1, concentrou-se em 60 Hz, enquanto, nos sinais PN00-1 a PN00-4, o ruído de linha localizou-se em 50 Hz.

De forma geral, a comparação entre a métrica e a inspeção visual do PSD mostrou que a leitura do ruído de linha não deve ser feita apenas a partir da métrica calculada em torno da frequência de interesse. Em vários sinais, sobretudo nos PN00-1, PN00-3 e PN00-4, os pipelines com ICA+ICLabel apresentaram aumentos ou alterações pouco intuitivas nesta métrica relativa, embora a inspeção visual do PSD mostrasse, de forma consistente, uma maior atenuação do pico estreito de ruído de linha face ao AutoReject isolado. Assim, o comportamento da métrica foi interpretado como uma medida de contraste espectral local e não como um indicador direto da quantidade absoluta de ruído remanescente.

Ainda assim, a leitura global dos sinais mostra um padrão relativamente estável. O AutoReject isolado foi, de forma consistente, o pipeline que menos atenuou o ruído de linha nas situações em que este estava presente. Os pipelines com ICA+ICLabel obtiveram, em geral, os melhores resultados visuais no PSD, quer em 60 Hz no sub00-1, quer em 50 Hz nos sinais PN00. Entre estes, o ICA+ICLabel isolado e o ICA+ICLabel+AutoReject apresentaram, na maioria dos casos, resultados muito próximos, sendo frequente que a aplicação posterior do AutoReject produzisse apenas diferenças pequenas. O AutoReject+ICA+ICLabel também mostrou melhorias face ao AutoReject isolado, mas de forma global menos marcada do que os pipelines em que o ICA+ICLabel atua primeiro.

4.2.3 Comparação visual global entre algoritmos

A comparação visual global no domínio temporal mostra, de forma consistente, que o AutoReject isolado não atingiu, em nenhum dos sinais analisados, o mesmo nível de limpeza

global obtido pelos pipelines com ICA+ICLabel. O contributo decisivo para a melhoria visual do traçado surge, assim, associado à introdução do bloco ICA+ICLabel, quer aplicado isoladamente, quer em pipelines híbridos. Em vários sinais, o AutoReject+ICA+ICLabel evidenciou melhoria clara face ao AutoReject isolado, confirmando que a etapa de ICA+ICLabel reduz artefactos residuais que o AutoReject, por si só, não consegue remover com a mesma eficácia. Ainda assim, esta ordem de aplicação manteve-se globalmente abaixo dos resultados obtidos quando o ICA+ICLabel atua primeiro.

A comparação principal centrou-se, por isso, entre ICA+ICLabel e ICA+ICLabel+AutoReject. De forma global, a aplicação posterior do AutoReject trouxe vantagens visuais relevantes em vários sinais, sobretudo na atenuação de artefactos pontuais de elevada amplitude e baixa frequência e na estabilização de canais contaminados por ruído de baixa amplitude e alta frequência ou por contaminação muscular residual. Esse comportamento foi repetidamente observado em canais específicos, como FC2 e T6 no PN00-1, F4 e C4 no PN00-3, e F7, Fz e P3 no PN00-4. No entanto, essa melhoria não foi uniforme em todos os casos. Nos sinais sub00-1 e PN00-4 observaram-se segmentos em que a interpolação introduziu alterações morfológicas locais em canais anteriormente aceitáveis, mostrando que o ganho do AutoReject pode coexistir com distorções pontuais.

4.2.4 Síntese operacional de execução

A comparação global da execução dos algoritmos mostra um padrão operacional relativamente consistente entre sinais. De forma geral, o ICA+ICLabel isolado foi o pipeline com menor tempo de execução, variando entre 30 e 40 segundos nos sinais mais curtos e 6 a 10 minutos nos sinais mais longos, mantendo um comportamento estável na decomposição e exclusão de componentes. Nos sinais clínicos, esta abordagem ajustou tipicamente entre 21 e 24 componentes, excluindo um número elevado de ICs, maioritariamente associadas a artefactos musculares, e produziu, em vários casos, aumentos relevantes de BSI.

O AutoReject isolado apresentou, em contraste, tempos de execução geralmente superiores e uma atuação muito dependente do número de epochs assinalados como maus. Nos sinais mais

contaminados, sinalizou volumes elevados de epochs irrecuperáveis, mantendo esses segmentos como originais no rebuild final. Em termos de parâmetros, o método operou com combinações de consensus entre 0,60 e 0,80 e n_interpolate entre 2 e 8, refletindo diferentes graus de permissividade na reparação local. Globalmente, o impacto do AutoReject isolado no BSI foi reduzido e em alguns sinais o valor diminuiu mesmo após o processamento.

Nos pipelines híbridos, a ordem de aplicação condicionou claramente o comportamento do sistema, não apenas ao nível da triagem de epochs e da decomposição ICA, mas também na variação do delta BSI. Quando o ICA+ICLabel foi aplicado primeiro, a decomposição e o conjunto de ICs excluídas mantiveram-se e o AutoReject passou a atuar como etapa adicional de reparação local, frequentemente com menos epochs sinalizados do que no AutoReject isolado, embora em alguns sinais tenha adotado parâmetros mais interventivos. Nessa configuração, o BSI tendeu a manter-se próximo do valor obtido com o ICA+ICLabel isolado. Quanto ao tempo total de execução, este aumentou de forma clara face ao ICA+ICLabel isolado. Quando a ordem foi invertida, o AutoReject manteve o perfil do caso isolado, mas o ICA+ICLabel passou frequentemente a ajustar mais componentes e a excluir um conjunto diferente de ICs. Nesta configuração, o delta BSI tendeu a assumir valores mais elevados do que no ICA+ICLabel+AutoReject, sendo mesmo o mais alto em quase todos os sinais. Esta configuração foi também, de forma consistente, a que apresentou os maiores tempos de execução.

5 Discussão

*Leitura crítica das
métricas
Justificação do
destaque do ICA+ICLabel
Aplicabilidade prática
das estratégias híbridas*

Nesta secção procede-se à discussão dos resultados obtidos, procurando interpretar de forma crítica o comportamento dos diferentes pipelines de pré-processamento à luz dos objetivos do estudo, das métricas utilizadas e das observações quantitativas e qualitativas realizadas ao longo da análise.

5.1 *Leitura crítica das métricas*

As métricas utilizadas neste trabalho revelaram-se úteis para identificar diferenças entre pipelines e descrever, de forma sistemática, a direção e a magnitude das alterações introduzidas pelo pré-processamento. No entanto, importa salientar que estas métricas devem ser entendidas como indicadores instrumentais de redução de artefactos e não como medidas diretas de qualidade clínica do sinal. Por outras palavras, uma variação favorável numa métrica específica não significa, por si só, que o sinal final seja globalmente mais adequado para interpretação neurofisiológica.

As métricas oculares e musculares mostraram-se úteis para captar, respetivamente, alterações na componente de baixa frequência frontal e na componente de alta frequência temporal, distinguindo de forma consistente o AutoReject dos pipelines com ICA+ICLabel. Ainda assim, o seu significado não é absoluto, pois reduções mais acentuadas nestes indicadores podem corresponder a uma remoção mais eficaz de artefactos, mas também a uma intervenção mais extensa sobre o conteúdo espectral do sinal. A mesma cautela foi necessária na leitura do ruído de linha, uma vez que, em vários sinais, a métrica em torno dos 50/60 Hz não acompanhou diretamente o comportamento observado no PSD, sugerindo que esta métrica reflete sobretudo alterações do contraste espectral local. Nos sinais com atividade ictal, o BSI acrescentou informação relevante sobre a assimetria espectral entre períodos pré-ictais e ictais, mas também não pôde ser interpretado isoladamente, já que a sua variação depende da forma como cada pipeline altera o balanço espectral entre hemisférios.

Em síntese, as métricas foram fundamentais para comparar os pipelines de forma objetiva e consistente, mas a sua interpretação só se tornou robusta quando cruzada com a inspeção visual do traçado temporal e do PSD. Foi precisamente essa leitura conjunta que permitiu distinguir

entre alterações quantitativas meramente instrumentais e mudanças que, de facto, correspondiam a melhorias ou limitações relevantes no sinal final.

5.2 Justificação do destaque do ICA+ICLabel

Entre os quatro pipelines avaliados, o ICA+ICLabel destacou-se como a abordagem mais consistente ao longo do conjunto de sinais analisados. Esse destaque não resulta apenas de um melhor desempenho em métricas isoladas, mas da combinação entre eficácia na redução de artefactos, estabilidade entre sinais e menor custo computacional. De forma global, foi o pipeline que produziu reduções mais acentuadas nas métricas oculares, alterações musculares mais marcadas e coerentes, melhor atenuação visual do ruído de linha no PSD, uma limpeza global mais evidente no domínio temporal e o que obteve o menor tempo de execução.

Em praticamente todos os sinais, o AutoReject isolado ficou aquém do ICA+ICLabel. Por sua vez, os pipelines híbridos mostraram que a aplicação posterior do AutoReject trouxe ganhos locais adicionais, sobretudo na atenuação de artefactos residuais pontuais. No entanto, esses ganhos surgiram como um refinamento sobre um resultado que já tinha sido largamente obtido pelo bloco ICA+ICLabel. Acresce que a etapa adicional de interpolação, em vários casos, esteve associada a distorções morfológicas locais e a alterações do traçado em canais anteriormente aceitáveis, introduzindo um nível adicional de risco que não se observou com a mesma frequência no ICA+ICLabel isolado.

Outro aspeto relevante foi a consistência entre sinais. Mesmo em registos com características muito diferentes, desde o MNE sample até aos sinais clínicos com atividade ictal, o comportamento do ICA+ICLabel manteve-se relativamente estável. O método não eliminou todos os artefactos em todos os casos, nem produziu sempre o melhor resultado possível em cada detalhe local, mas foi o pipeline que apresentou o desempenho global mais previsível. Essa previsibilidade é particularmente importante quando se pensa na construção de um pipeline automático, em que a robustez entre sinais pode ser tão importante quanto o desempenho máximo em casos individuais.

Assim, o ICA+ICLabel sobressaiu por concentrar, de forma mais consistente, a maior parte do ganho de limpeza observado, com menor tempo de execução e maior estabilidade entre sinais. A sua superioridade, neste contexto, não deve ser entendida como absoluta ou universal, mas como a solução que apresentou o melhor equilíbrio global dentro das condições, sinais e critérios considerados neste estudo. Neste sentido, os resultados sustentam a sua escolha como base principal do pipeline de pré-processamento, por reunir simultaneamente eficácia na redução de artefactos, previsibilidade de comportamento e viabilidade computacional.

5.3 Aplicabilidade prática das estratégias híbridas

Os resultados mostram que os pipelines híbridos podem acrescentar valor, mas esse valor não foi uniforme nem automático. Entre as duas combinações testadas, o ICA+ICLabel+AutoReject foi a que mais vezes evidenciou melhorias adicionais com significado visual. Essas melhorias surgiram sobretudo na atenuação de artefactos pontuais de elevada amplitude e baixa frequência, na estabilização local de canais ainda contaminados por ruído residual e na correção de episódios localizados que permaneciam após a aplicação do ICA+ICLabel. Nesses casos, o AutoReject funcionou como uma etapa complementar de refinamento, atuando sobre resíduos que a decomposição em componentes independentes não tinha eliminado totalmente.

Contudo, esse ganho não foi constante. Em vários sinais, a melhoria introduzida pelo AutoReject após o ICA+ICLabel foi apenas marginal e, em alguns casos, veio acompanhada de efeitos indesejáveis, como alterações morfológicas locais ao interpolar canais anteriormente aceitáveis e o aumento do tempo total de execução. Isto mostra que combinar métodos não garantiu, por si só, um melhor resultado. O benefício do pipeline híbrido dependeu do tipo de artefacto, da distribuição espacial da contaminação e da forma como a interpolação afetou o traçado em segmentos específicos.

O comportamento do AutoReject+ICA+ICLabel foi diferente. Esta combinação mostrou-se claramente superior ao AutoReject isolado, o que confirma a utilidade da introdução posterior do bloco ICA+ICLabel. Ainda assim, os seus resultados mantiveram-se abaixo dos pipelines em que o ICA+ICLabel atuou como primeira etapa.

Em síntese, os pipelines híbridos mostraram utilidade sobretudo como estratégias de refinamento, e não como solução de primeira linha. O AutoReject revelou maior interesse quando aplicado sobre um sinal já parcialmente limpo pelo ICA+ICLabel, atuando localmente sobre artefactos residuais. Ainda assim, esse benefício foi variável e nem sempre compensou o aumento de complexidade, de custo computacional e do risco de introduzir novas distorções no traçado. Em termos práticos, estes resultados apontam para uma utilização seletiva do AutoReject como etapa complementar e não como componente obrigatória do pipeline final.

6 Conclusão

Conclusão
Trabalhos Futuros
Comentários

6.1 Conclusão

O presente trabalho teve como objetivo analisar e comparar diferentes estratégias de pré-processamento de sinais de EEG orientadas para a remoção de artefactos, procurando identificar uma solução que combinasse automatização, robustez, reprodutibilidade e custo computacional controlado. Para esse efeito, foram estudados métodos convencionais, automáticos e híbridos descritos na literatura, tendo a componente experimental incidido sobretudo na comparação entre os pipelines AutoReject, ICA+ICLabel e diferentes combinações entre ambos.

A revisão do estado da arte mostrou que a remoção de artefactos em EEG continua a ser um problema complexo, não existindo uma abordagem universalmente superior para todos os contextos. Ainda assim, tornou-se claro que os métodos de separação cega de fontes, em particular a ICA, mantêm um papel central na literatura, enquanto os métodos automáticos têm vindo a assumir crescente relevância pela sua capacidade de reduzir a subjetividade da inspeção manual e aumentar a escalabilidade das pipelines de pré-processamento.

Os resultados obtidos neste estudo mostraram que o ICA+ICLabel foi a abordagem que apresentou o comportamento global mais consistente entre sinais. De forma geral, este pipeline evidenciou melhor capacidade de redução das métricas oculares e musculares, melhor atenuação do ruído de linha, maior qualidade global no traçado temporal e, simultaneamente, menor tempo de execução. Em contraste, o AutoReject isolado revelou utilidade mais limitada, funcionando melhor como mecanismo de tratamento de segmentos contaminados do que como núcleo principal de limpeza do sinal.

Relativamente às abordagens híbridas, observou-se que a aplicação do AutoReject após o ICA+ICLabel podia, em alguns sinais, introduzir melhorias locais adicionais, sobretudo na atenuação de artefactos pontuais de elevada amplitude e na estabilização de canais com contaminação residual. No entanto, esses ganhos foram frequentemente marginais, dependentes do sinal e, por vezes, acompanhados por aumento do custo computacional e por distorções morfológicas locais. Já a ordem inversa, AutoReject+ICA+ICLabel, mostrou-se globalmente menos eficaz, além de apresentar os maiores tempos de execução.

Deste modo, conclui-se que a solução que oferece o melhor compromisso entre qualidade de limpeza, consistência entre sinais e viabilidade prática é o pipeline baseado em ICA+ICLabel. O AutoReject mantém interesse como ferramenta complementar, sobretudo quando aplicado de forma seletiva como etapa de refinamento posterior, e não como componente central obrigatória do pipeline. Esta conclusão é coerente tanto com os resultados experimentais obtidos como com a leitura crítica do estado da arte.

Como limitações, importa reconhecer que os resultados dependem do conjunto de sinais analisados e das métricas utilizadas, pelo que a generalização a outros contextos deverá ser feita com prudência.

6.2 Trabalhos Futuros

Embora os resultados obtidos permitam identificar uma direção metodológica clara, existem ainda vários aspetos que poderão ser aprofundados em trabalhos futuros. Em primeiro lugar, será importante validar o pipeline selecionado num conjunto mais alargado e heterogéneo de sinais EEG. Esta etapa permitirá perceber até que ponto o comportamento observado neste trabalho se mantém em outros cenários.

Em segundo lugar, poderá ser desenvolvido um refinamento adicional do pipeline baseado em ICA+ICLabel, explorando de forma mais sistemática em que condições a aplicação posterior do AutoReject traz efetivamente benefícios e em que situações tende apenas a aumentar a complexidade ou o risco de distorção local do sinal. Esta análise poderá permitir definir critérios objetivos para a utilização condicional desta etapa complementar, tornando o pipeline mais adaptativo ao tipo e ao grau de contaminação do registo.

Por fim, um desenvolvimento futuro particularmente relevante consiste na integração do pipeline final numa solução automática ou semi-automática de utilização prática, nomeadamente numa aplicação baseada em Python/MNE. Esta integração permitirá transformar os resultados deste trabalho numa ferramenta de pré-processamento mais reprodutível, auditável e potencialmente aplicável a fluxos de análise contínua, aproximando a proposta metodológica do contexto real de utilização.

6.3 Comentários

O curso de Engenharia Biomédica foi desafiante, na medida em que exigiu adaptabilidade ao conteúdo de cada unidade curricular. Um engenheiro biomédico tem de ser capaz de ver pelos vários espectros e áreas de engenharia de um ângulo, ora superficial, ora detalhado e essa característica está muito bem refletida no plano de estudos.

Bibliografia

- Al-Fahoum, A. S., & Al-Fraihat, A. A. (2014). Methods of EEG Signal Features Extraction Using Linear Analysis in Frequency and Time-Frequency Domains. *ISRN Neuroscience*, 2014, 1–7. <https://doi.org/10.1155/2014/730218>
- Carvalho, V. R., Moraes, M. F. D., Braga, A. P., & Mendes, E. M. A. M. (2020). Evaluating five different adaptive decomposition methods for EEG signal seizure detection and classification. *Biomedical Signal Processing and Control*, 62, 102073. <https://doi.org/10.1016/J.BSPC.2020.102073>
- Chaumon, M., Bishop, D. V. M., & Busch, N. A. (2015). A practical guide to the selection of independent components of the electroencephalogram for artifact correction. *Journal of Neuroscience Methods*, 250, 47–63. <https://doi.org/10.1016/J.JNEUMETH.2015.02.025>
- Chen, Q., Li, Y., & Yuan, X. (2021). A hybrid method for muscle artifact removal from EEG signals. *Journal of Neuroscience Methods*, 353. <https://doi.org/10.1016/J.JNEUMETH.2021.109104>
- Chen, X., Liu, A., Chiang, J., Wang, Z. J., McKeown, M. J., & Ward, R. K. (2016). Removing Muscle Artifacts from EEG Data: Multichannel or Single-Channel Techniques? *IEEE Sensors Journal*, 16(7), 1986–1997. <https://doi.org/10.1109/JSEN.2015.2506982>
- Choi, S., Riken, A. C., Park, H.-M., & Lee, S.-Y. (2005). *Blind Source Separation and Independent Component Analysis: A Review*.
- Crisan, D. (2001). Particle Filters — A Theoretical Perspective. *Sequential Monte Carlo Methods in Practice*, 17–41. https://doi.org/10.1007/978-1-4757-3437-9_2
- Croft, R. J., & Barry, R. J. (2000). Removal of ocular artifact from the EEG: a review. *Neurophysiologie Clinique = Clinical Neurophysiology*, 30(1), 5–19. [https://doi.org/10.1016/S0987-7053\(00\)00055-1](https://doi.org/10.1016/S0987-7053(00)00055-1)
- Davies, M. E., & James, C. J. (2007). Source separation using single channel ICA. *Signal Processing*, 87(8), 1819–1832. <https://doi.org/10.1016/J.SIGPRO.2007.01.011>
- Delorme, A. (2023). EEG is better left alone. *Scientific Reports* 2023 13:1, 13(1), 2372-. <https://doi.org/10.1038/s41598-023-27528-0>
- Delorme, A., Truong, D., Pion-Tonachini, L., & Makeig, S. (2024). Automatic EEG Independent Component Classification Using ICLabel in Python. *Proceedings - 2024 IEEE International Conference on Bioinformatics and Biomedicine, BIBM 2024*, 4137–4141. <https://doi.org/10.1109/BIBM62325.2024.10822445>

- Deti, P., Vatti, G., & de Lara, G. Z. M. (2020). EEG synchronization analysis for seizure prediction: A study on data of noninvasive recordings. *Processes*, 8(7). <https://doi.org/10.3390/PR8070846>
- Tuna, M. (2024). *Doenças neurodegenerativas atingem mais de 3 mil milhões de pessoas em todo o mundo - Expresso*. <https://expresso.pt/longevidade/2024-10-23-video-doencas-neurodegenerativas-atingem-mais-de-3-mil-milhoes-de-pessoas-em-todo-o-mundo-bfbc5844>
- Dragomiretskiy, K., & Zosso, D. (2014). Variational mode decomposition. *IEEE Transactions on Signal Processing*, 62(3), 531–544. <https://doi.org/10.1109/TSP.2013.2288675>
- Echtioui, A., Zouch, W., Ghorbel, M., Slima, M. Ben, Hamida, A. Ben, & Mhiri, C. (2020). Automated EEG Artifact Detection Using Independent Component Analysis. *2020 International Conference on Advanced Technologies for Signal and Image Processing, ATSIP 2020*. <https://doi.org/10.1109/ATSIP49331.2020.9231574>
- BrainVision. (2023). *EEG Preprocessing – Setting up your data for optimal analysis | GoToStage.com*. <https://www.gotostage.com/channel/a26a09b972b84c52a391a16dfb4298e9/recording/167e7ff278bf432f9ba300bb1868651a/watch>
- Fatourechi, M., Bashashati, A., Ward, R. K., & Birch, G. E. (2007). EMG and EOG artifacts in brain computer interface systems: A survey. *Clinical Neurophysiology: Official Journal of the International Federation of Clinical Neurophysiology*, 118(3), 480–494. <https://doi.org/10.1016/J.CLINPH.2006.10.019>
- Feigin, V. L., Stark, B. A., Johnson, C. O., Roth, G. A., Bisignano, C., Abady, G. G., Abbasifard, M., Abbasi-Kangevari, M., Abd-Allah, F., Abedi, V., Abualhasan, A., Abu-Rmeileh, N. M. E., Abushouk, A. I., Adebayo, O. M., Agarwal, G., Agasthi, P., Ahinkorah, B. O., Ahmad, S., Ahmadi, S., ... Murray, C. J. L. (2021). Global, regional, and national burden of stroke and its risk factors, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019. *The Lancet Neurology*, 20(10), 795–820. [https://doi.org/10.1016/S1474-4422\(21\)00252-0](https://doi.org/10.1016/S1474-4422(21)00252-0)
- Garcés Correa, A., Laciari, E., Patão, H. D., & Valentinuzzi, M. E. (2007). Artifact removal from EEG signals using adaptive filters in cascade. *Journal of Physics: Conference Series*, 90(1), 012081. <https://doi.org/10.1088/1742-6596/90/1/012081>

- Gorjan, D., Gramann, K., De Pauw, K., & Marusic, U. (2022). Removal of movement-induced EEG artifacts: current state of the art and guidelines. *Journal of Neural Engineering*, 19(1), 011004. <https://doi.org/10.1088/1741-2552/AC542C>
- Gramfort, A. (2010). *Datasets Overview — MNE 1.12.1 documentation*. <https://mne.tools/stable/documentation/datasets.html>
- Iatsenko, D., McClintock, P. V. E., & Stefanovska, A. (2015). Nonlinear mode decomposition: A noise-robust, adaptive decomposition method. *Physical Review E - Statistical, Nonlinear, and Soft Matter Physics*, 92(3). <https://doi.org/10.1103/PHYSREVE.92.032916>
- Ille, N., Nakao, Y., Yano, S., Taura, T., Ebert, A., Bornfleth, H., Asagi, S., Kozawa, K., Itabashi, I., Sato, T., Sakuraba, R., Tsuda, R., Kakisaka, Y., Jin, K., & Nakasato, N. (2024). Ongoing EEG artifact correction using blind source separation. *Clinical Neurophysiology*, 158, 149–158. <https://doi.org/10.1016/J.CLINPH.2023.12.133>
- Jas, M., Engemann, D. A., Bekhti, Y., Raimondo, F., & Gramfort, A. (2017). Autoreject: Automated artifact rejection for MEG and EEG data. *NeuroImage*, 159, 417–429. <https://doi.org/10.1016/J.NEUROIMAGE.2017.06.030>
- Jiang, X., Bian, G. Bin, & Tian, Z. (2019). Removal of Artifacts from EEG Signals: A Review. *Sensors (Basel, Switzerland)*, 19(5), 987. <https://doi.org/10.3390/S19050987>
- Kim, T., Eltoft, T., & Lee, T. W. (2006). Independent Vector Analysis: An Extension of ICA to Multivariate Components. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 3889 LNCS, 165–172. https://doi.org/10.1007/11679363_21
- Kline, J. E., Huang, H. J., & Snyder, K. L. (2022). *Removal of movement-induced EEG artifacts: current state of the art and guidelines*. <https://doi.org/10.1088/1741-2552/ac542c>
- Krishnaveni, V., Jayaraman, S., Anitha, L., & Ramadoss, K. (2006). Removal of ocular artifacts from EEG using adaptive thresholding of wavelet coefficients. *Journal of Neural Engineering*, 3(4), 338. <https://doi.org/10.1088/1741-2560/3/4/011>
- Li, A., Feitelberg, J., Saini, A. P., Höchenberger, R., & Scheltienne, M. (2022). MNE-ICALabel: Automatically annotating ICA components with ICLabel in Python. *Journal of Open Source Software*. <https://doi.org/10.21105/joss.04484>
- Mahajan, R., & Morshed, B. (2013). *Sample Entropy Enhanced Wavelet-ICA Denoising Technique for Eye Blink Artifact Removal from Scalp EEG Dataset*. https://doi.org/10.0/Linux-x86_64

- Mognon, A., Jovicich, J., Bruzzone, L., & Buiatti, M. (2011). ADJUST: An automatic EEG artifact detector based on the joint use of spatial and temporal features. *Psychophysiology*, 48(2), 229–240. <https://doi.org/10.1111/J.1469-8986.2010.01061.X>
- Molla, M. K. I., Rabiul Islam, M., Tanaka, T., & Rutkowski, T. M. (2012). Artifact suppression from EEG signals using data adaptive time domain filtering. *Neurocomputing*, 97, 297–308. <https://doi.org/10.1016/J.NEUCOM.2012.05.009>
- Muthukumaraswamy, S. D. (2013). High-frequency brain activity and muscle artifacts in MEG/EEG: A review and recommendations. *Frontiers in Human Neuroscience*, 7(MAR), 47068. <https://doi.org/10.3389/FNHUM.2013.00138/XML>
- Nolan, H., Whelan, R., & Reilly, R. B. (2010). FASTER: Fully Automated Statistical Thresholding for EEG artifact Rejection. *Journal of Neuroscience Methods*, 192(1), 152–162. <https://doi.org/10.1016/J.JNEUMETH.2010.07.015>
- Perucca, P., Dubeau, F., & Gotman, J. (2013). Widespread EEG changes precede focal seizures. *PLoS One*, 8(11). <https://doi.org/10.1371/JOURNAL.PONE.0080972>
- Pion-Tonachini, L., Kreutz-Delgado, K., & Makeig, S. (2019). ICLabel: An automated electroencephalographic independent component classifier, dataset, and website. *NeuroImage*, 198, 181–197. <https://doi.org/10.1016/J.NEUROIMAGE.2019.05.026>
- Rankaduwa, S. (2025). *GitHub - neural-data-science/NESC_3505: Official website for the course NESC 3505 Neural Data Science, at Dalhousie University (Halifax, NS, Canada).* · GitHub. https://github.com/neural-data-science/NESC_3505
- Romero, S., Mañanas, M. A., & Barbanoj, M. J. (2009). Ocular reduction in EEG signals based on adaptive filtering, regression and blind source separation. *Annals of Biomedical Engineering*, 37(1), 176–191. <https://doi.org/10.1007/S10439-008-9589-6/FIGURES/9>
- Roy, V., Shukla, P. K., Gupta, A. K., Goel, V., Shukla, P. K., & Shukla, S. (2021). Taxonomy on EEG artifacts removal methods, issues, and healthcare applications. *Journal of Organizational and End User Computing*, 33(1), 19–46. <https://doi.org/10.4018/JOEUC.2021010102>
- Safieddine, D., Kachenoura, A., Albera, L., Birot, G., Karfoul, A., Pasnicu, A., Biraben, A., Wendling, F., Senhadji, L., & Merlet, I. (2012). Removal of muscle artifact from EEG data: Comparison between stochastic (ICA and CCA) and deterministic (EMD and wavelet-based) approaches. *Eurasip Journal on Advances in Signal Processing*, 2012(1), 127-. <https://doi.org/10.1186/1687-6180-2012-127/FIGURES/6>

- Sweeney, K. T., Ward, T. E., & McLoone, S. F. (2012). Artifact removal in physiological signals-practices and possibilities. *IEEE Transactions on Information Technology in Biomedicine*, 16(3), 488–500. <https://doi.org/10.1109/TITB.2012.2188536>
- Talebi, S. (2020). *The Wavelet Transform / Towards Data Science*. <https://towardsdatascience.com/the-wavelet-transform-e9cfa85d7b34/>
- Urigüen, J. A., & Garcia-Zapirain, B. (2015). EEG artifact removal-state-of-the-art and guidelines. *Journal of Neural Engineering*, 12(3). <https://doi.org/10.1088/1741-2560/12/3/031001>
- Wainwright Royal Society, J. (1998). 96PA259. <https://doi.org/10.1098/rspa.1998.0193>
- Welch, G., & Bishop, G. (2006). *An Introduction to the Kalman Filter*. <http://www.cs.unc.edu/~gb>
- Wu, Z., & Huang, N. E. (2009). Ensemble empirical mode decomposition: A noise-assisted data analysis method. *Advances in Adaptive Data Analysis*, 1(1), 1–41. <https://doi.org/10.1142/S1793536909000047>
- Xu, X., Chen, X., & Yu, Z. (2018). Removal of muscle artefacts from few-channel EEG recordings based on multivariate empirical mode decomposition and independent vector analysis. *Electronics Letters*, 54(14), 866–868. <https://doi.org/10.1049/EL.2018.0191>
- Yilmaz, G., Budan, A. S., Ungan, P., Topkara, B., & Türker, K. S. (2019). Facial muscle activity contaminates EEG signal at rest: evidence from frontalis and temporalis motor units. *Journal of Neural Engineering*, 16(6). <https://doi.org/10.1088/1741-2552/AB3235>
- Yong, X., Ward, R. K., & Birch, G. E. (2009). Artifact removal in EEG using morphological component analysis. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, 345–348. <https://doi.org/10.1109/ICASSP.2009.4959591>

